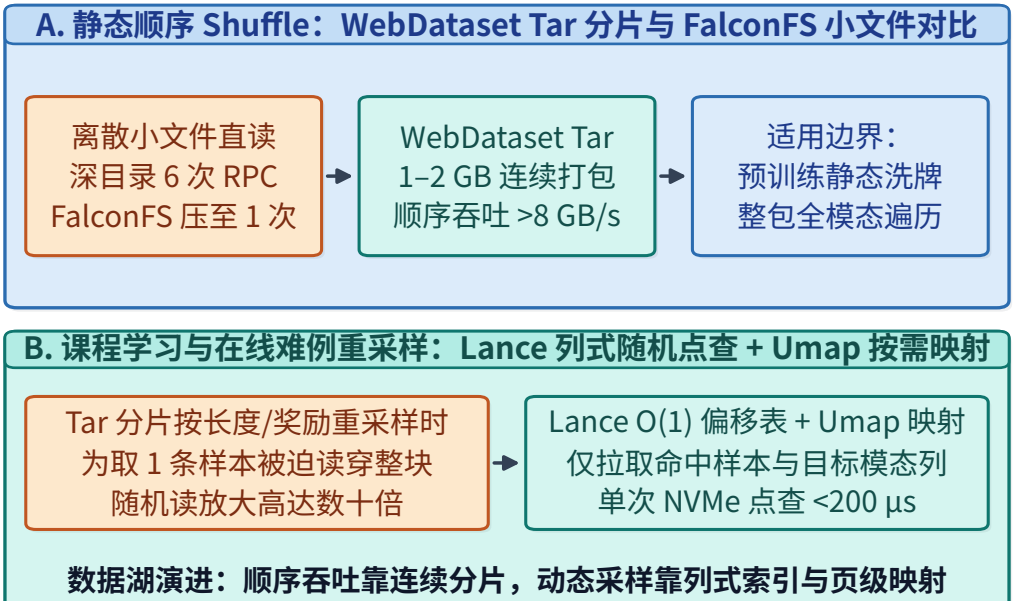
A. 静态顺序 Shuffle：WebDataset Tar 分片与 FalconFS 小文件对比
离散小文件直读
深目录 6 次 RPC
FalconFS 压至 1 次
WebDataset Tar
1–2 GB 连续打包
顺序吞吐 >8 GB/s
适用边界：
预训练静态洗牌
整包全模态遍历
B. 课程学习与在线难例重采样：Lance 列式随机点查 + Umap 按需映射
Tar 分片按长度/奖励重采样时
为取 1 条样本被迫读穿整块
随机读放大高达数十倍
Lance O(1) 偏移表 + Umap 映射
仅拉取命中样本与目标模态列
单次 NVMe 点查 <200 µs
数据湖演进：顺序吞吐靠连续分片，动态采样靠列式索引与页级映射