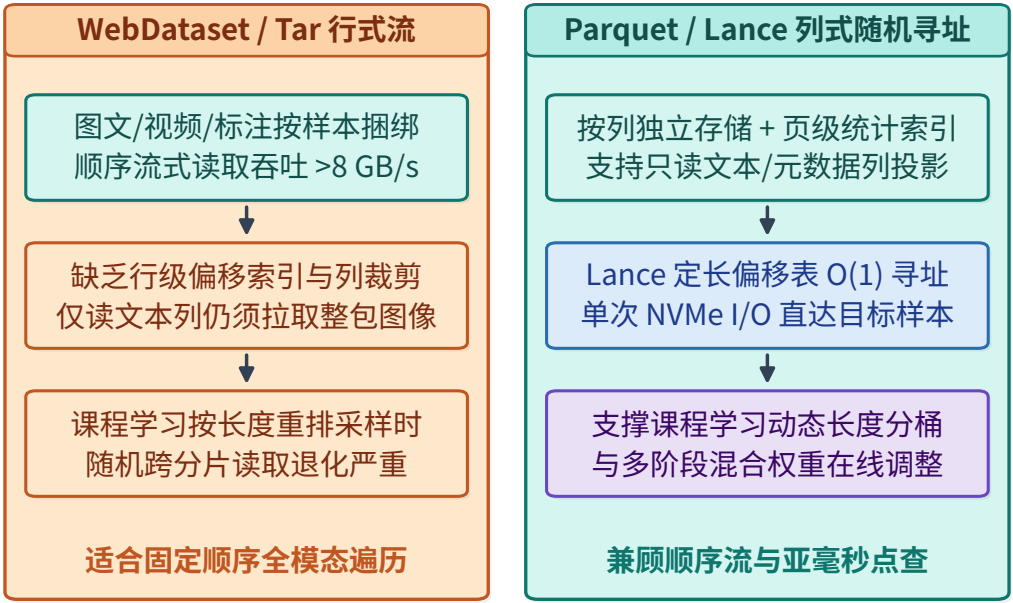
WebDataset / Tar 行式流
图文/视频/标注按样本捆绑
顺序流式读取吞吐 >8 GB/s
缺乏行级偏移索引与列裁剪
仅读文本列仍须拉取整包图像
课程学习按长度重排采样时
随机跨分片读取退化严重
适合固定顺序全模态遍历
Parquet / Lance 列式随机寻址
按列独立存储 + 页级统计索引
支持只读文本/元数据列投影
Lance 定长偏移表 O(1) 寻址
单次 NVMe I/O 直达目标样本
支撑课程学习动态长度分桶
与多阶段混合权重在线调整
兼顾顺序流与亚毫秒点查