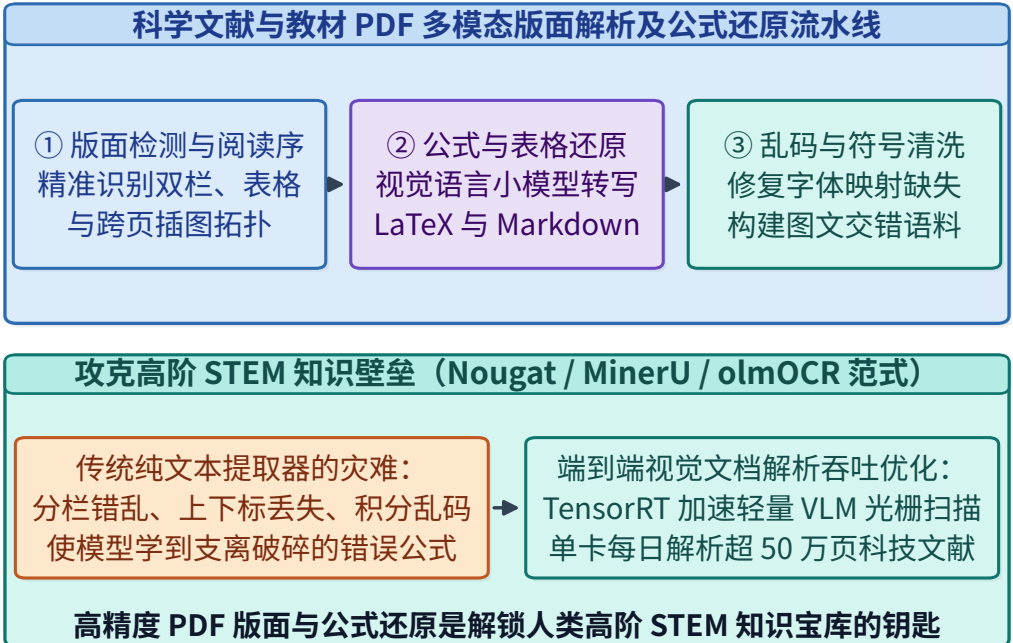
科学文献与教材 PDF 多模态版面解析及公式还原流水线
① 版面检测与阅读序
精准识别双栏、表格
与跨页插图拓扑
② 公式与表格还原
视觉语言小模型转写
LaTeX 与 Markdown
③ 乱码与符号清洗
修复字体映射缺失
构建图文交错语料
攻克高阶 STEM 知识壁垒（Nougat / MinerU / olmOCR 范式）
传统纯文本提取器的灾难：
分栏错乱、上下标丢失、积分乱码
使模型学到支离破碎的错误公式
端到端视觉文档解析吞吐优化：
TensorRT 加速轻量 VLM 光栅扫描
单卡每日解析超 50 万页科技文献
高精度 PDF 版面与公式还原是解锁人类高阶 STEM 知识宝库的钥匙