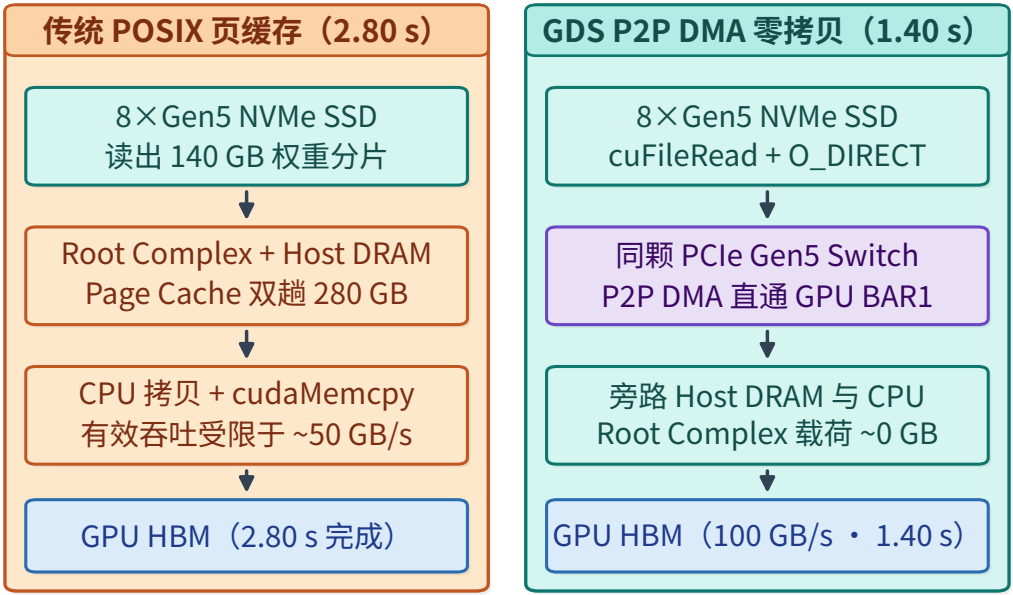
传统 POSIX 页缓存（2.80 s）
8×Gen5 NVMe SSD
读出 140 GB 权重分片
Root Complex + Host DRAM
Page Cache 双趟 280 GB
CPU 拷贝 + cudaMemcpy
有效吞吐受限于 ~50 GB/s
GPU HBM（2.80 s 完成）
GDS P2P DMA 零拷贝（1.40 s）
8×Gen5 NVMe SSD
cuFileRead + O_DIRECT
同颗 PCIe Gen5 Switch
P2P DMA 直通 GPU BAR1
旁路 Host DRAM 与 CPU
Root Complex 载荷 ~0 GB
GPU HBM（100 GB/s · 1.40 s）