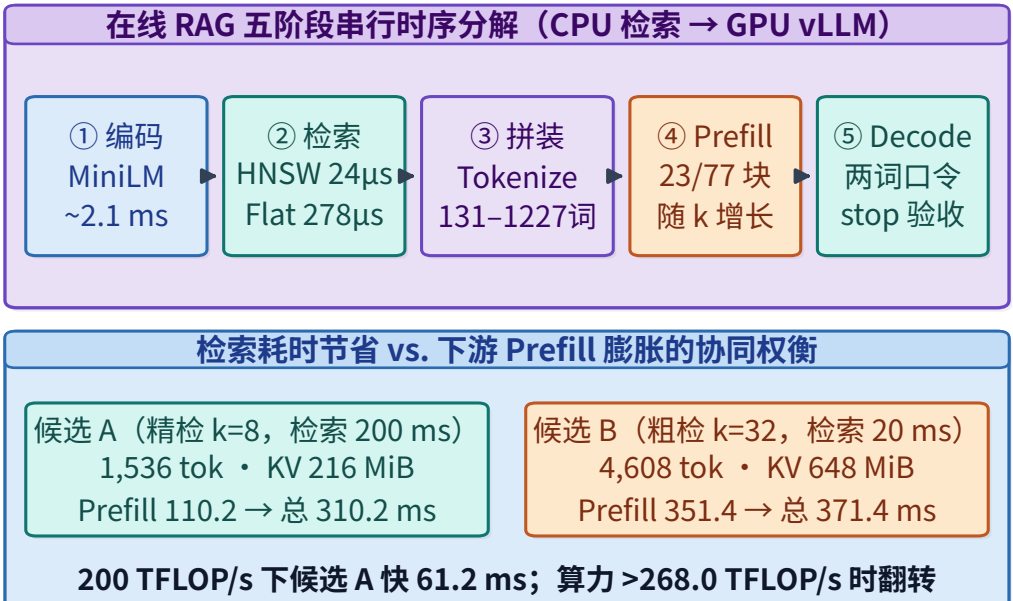
在线 RAG 五阶段串行时序分解（CPU 检索 → GPU vLLM）
① 编码
MiniLM
~2.1 ms
② 检索
HNSW 24μs
Flat 278μs
③ 拼装
Tokenize
131–1227词
④ Prefill
23/77 块
随 k 增长
⑤ Decode
两词口令
stop 验收
检索耗时节省 vs. 下游 Prefill 膨胀的协同权衡
候选 A（精检 k=8，检索 200 ms）
1,536 tok · KV 216 MiB
Prefill 110.2 → 总 310.2 ms
候选 B（粗检 k=32，检索 20 ms）
4,608 tok · KV 648 MiB
Prefill 351.4 → 总 371.4 ms
200 TFLOP/s 下候选 A 快 61.2 ms；算力 >268.0 TFLOP/s 时翻转