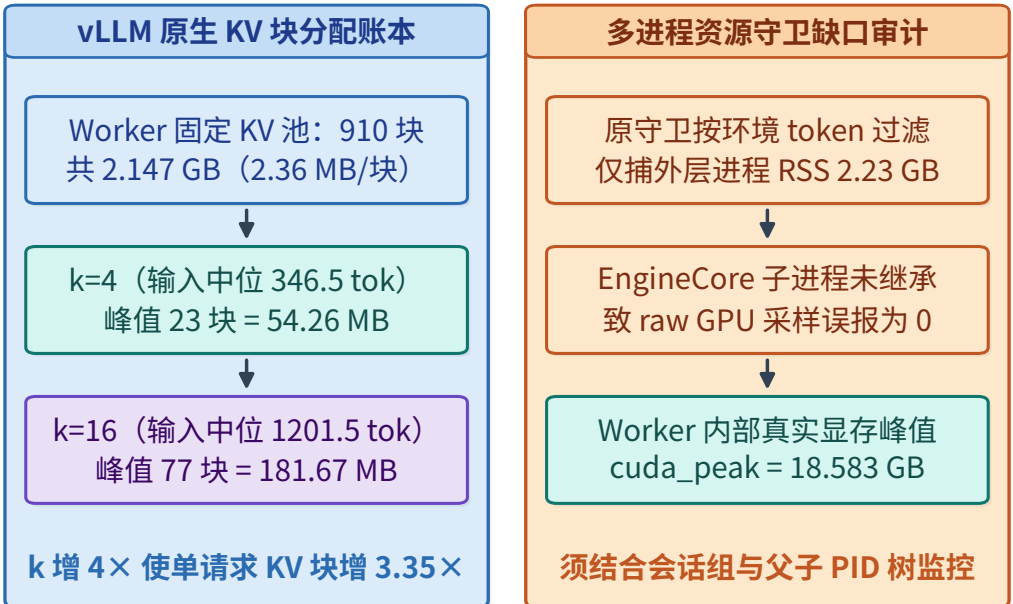
vLLM 原生 KV 块分配账本
Worker 固定 KV 池：910 块
共 2.147 GB（2.36 MB/块）
k=4（输入中位 346.5 tok）
峰值 23 块 = 54.26 MB
k=16（输入中位 1201.5 tok）
峰值 77 块 = 181.67 MB
k 增 4× 使单请求 KV 块增 3.35×
多进程资源守卫缺口审计
原守卫按环境 token 过滤
仅捕外层进程 RSS 2.23 GB
EngineCore 子进程未继承
致 raw GPU 采样误报为 0
Worker 内部真实显存峰值
cuda_peak = 18.583 GB
须结合会话组与父子 PID 树监控