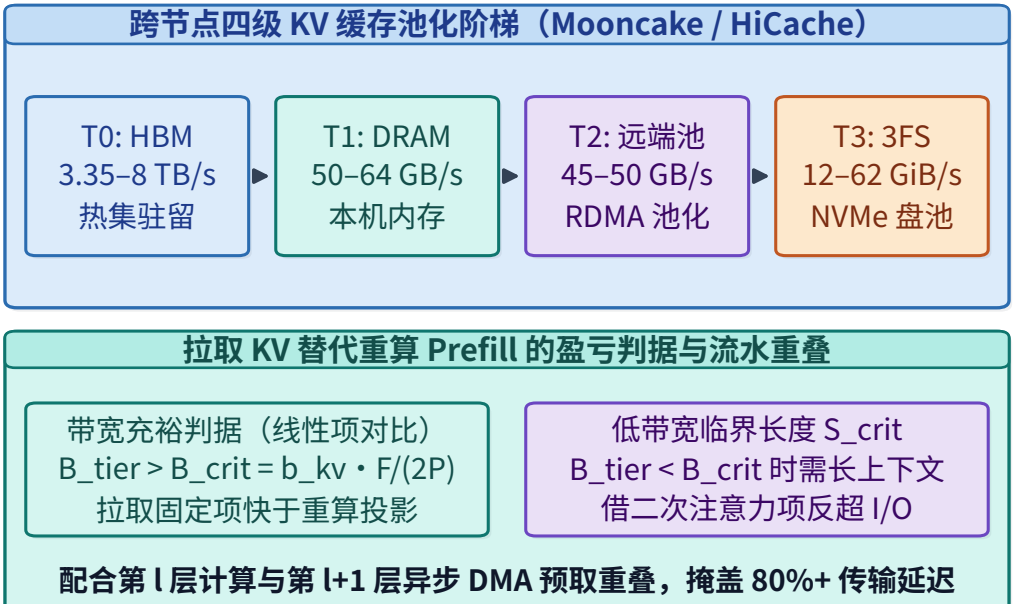
跨节点四级 KV 缓存池化阶梯（Mooncake / HiCache）
T0: HBM
3.35–8 TB/s
热集驻留
T1: DRAM
50–64 GB/s
本机内存
T2: 远端池
45–50 GB/s
RDMA 池化
T3: 3FS
12–62 GiB/s
NVMe 盘池
拉取 KV 替代重算 Prefill 的盈亏判据与流水重叠
带宽充裕判据（线性项对比）
B_tier > B_crit = b_kv · F/(2P)
拉取固定项快于重算投影
低带宽临界长度 S_crit
B_tier < B_crit 时需长上下文
借二次注意力项反超 I/O
配合第 l 层计算与第 l+1 层异步 DMA 预取重叠，掩盖 80%+ 传输延迟