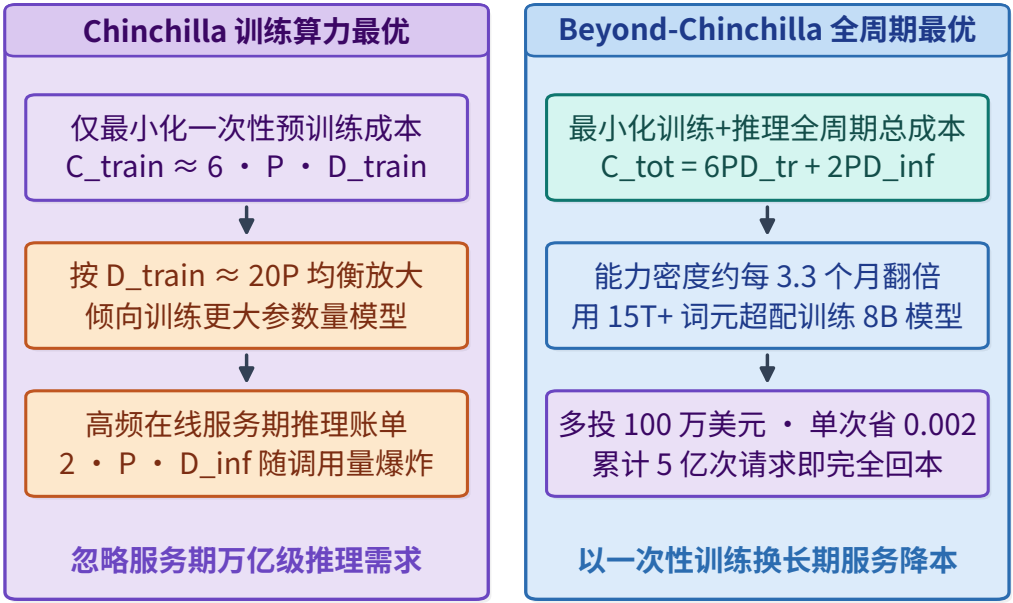
Chinchilla 训练算力最优
仅最小化一次性预训练成本
C_train ≈ 6 · P · D_train
按 D_train ≈ 20P 均衡放大
倾向训练更大参数量模型
高频在线服务期推理账单
2 · P · D_inf 随调用量爆炸
忽略服务期万亿级推理需求
Beyond-Chinchilla 全周期最优
最小化训练+推理全周期总成本
C_tot = 6PD_tr + 2PD_inf
能力密度约每 3.3 个月翻倍
用 15T+ 词元超配训练 8B 模型
多投 100 万美元 · 单次省 0.002
累计 5 亿次请求即完全回本
以一次性训练换长期服务降本