硬件物理边界内化为模型架构正则项的跨层耦合

微缩块量化（MXFP4 32元素）
约束激活离群值与谱范数

SFU 与 Tensor Core 配比
约束 Softmax 频次与能耗

HBM 容量与 SSD 块粒度
约束持久 KV 与跨层共享

超节点互连半径与跳数
约束专家度与状态重放

协同设计的四大定量杠杆（Four Co-Design Levers）

① 数值分布整形
RoPE-post 与正交旋转

② 跨层状态锚点化
CSA2 4-Owner 共享 KV

③ 有界重算代传输
128-token SWA 局部重放

④ 前向计算重分布
CED 早期丢弃与深编码