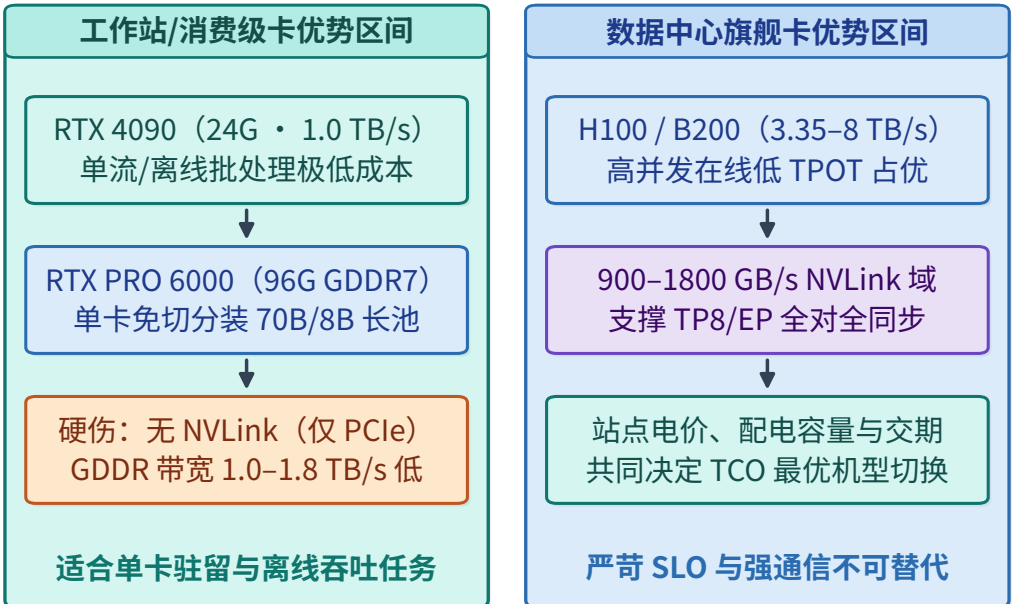
工作站/消费级卡优势区间
RTX 4090（24G · 1.0 TB/s）
单流/离线批处理极低成本
RTX PRO 6000（96G GDDR7）
单卡免切分装 70B/8B 长池
硬伤：无 NVLink（仅 PCIe）
GDDR 带宽 1.0–1.8 TB/s 低
适合单卡驻留与离线吞吐任务
数据中心旗舰卡优势区间
H100 / B200（3.35–8 TB/s）
高并发在线低 TPOT 占优
900–1800 GB/s NVLink 域
支撑 TP8/EP 全对全同步
站点电价、配电容量与交期
共同决定 TCO 最优机型切换
严苛 SLO 与强通信不可替代