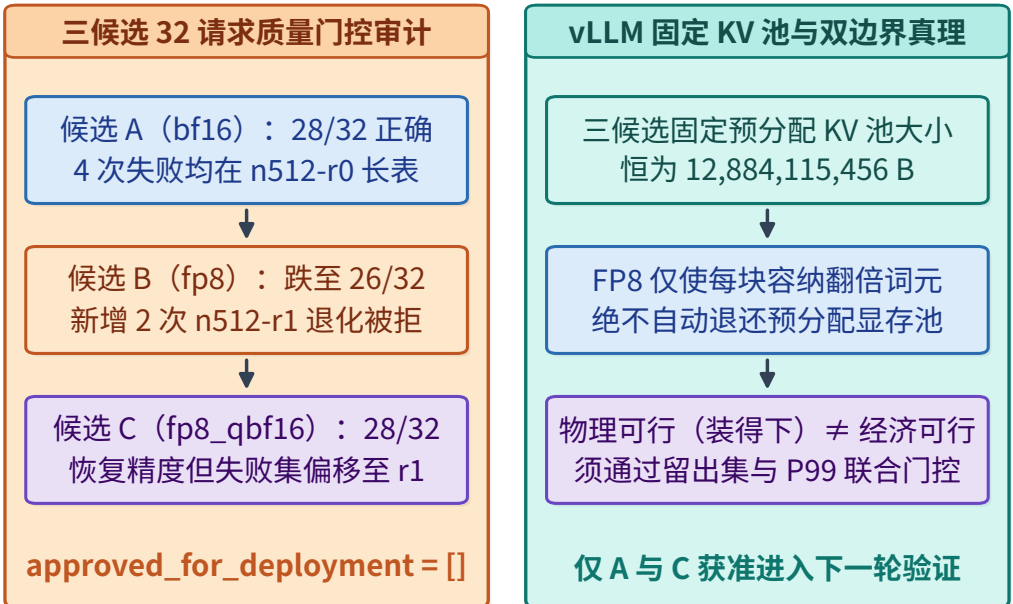
三候选 32 请求质量门控审计
候选 A（bf16）：28/32 正确
4 次失败均在 n512-r0 长表
候选 B（fp8）：跌至 26/32
新增 2 次 n512-r1 退化被拒
候选 C（fp8_qbf16）：28/32
恢复精度但失败集偏移至 r1
approved_for_deployment = []
vLLM 固定 KV 池与双边界真理
三候选固定预分配 KV 池大小
恒为 12,884,115,456 B
FP8 仅使每块容纳翻倍词元
绝不自动退还预分配显存池
物理可行（装得下）≠ 经济可行
须通过留出集与 P99 联合门控
仅 A 与 C 获准进入下一轮验证