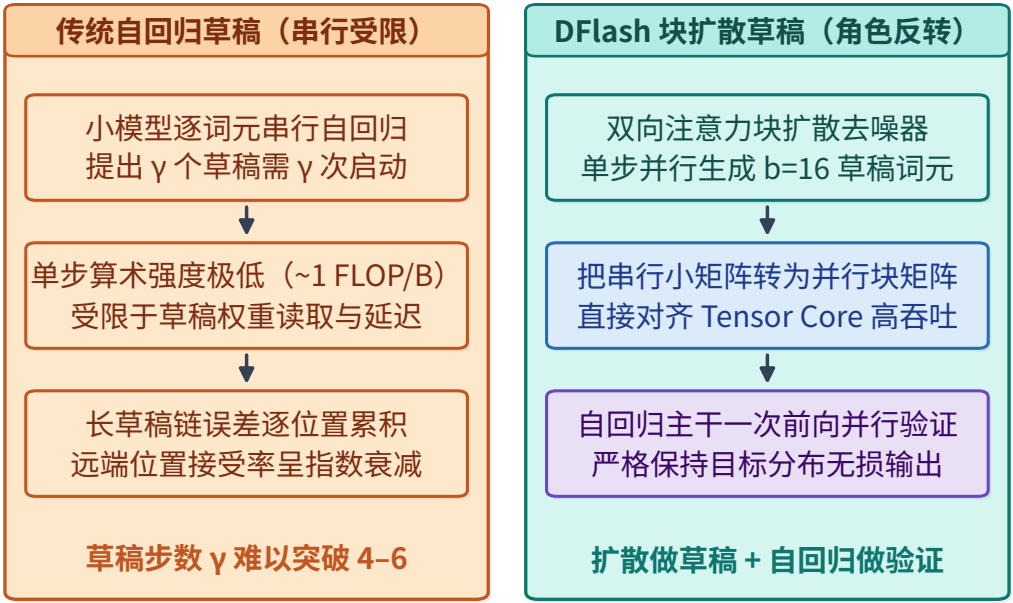
传统自回归草稿（串行受限）
小模型逐词元串行自回归
提出 γ 个草稿需 γ 次启动
单步算术强度极低（~1 FLOP/B）
受限于草稿权重读取与延迟
长草稿链误差逐位置累积
远端位置接受率呈指数衰减
草稿步数 γ 难以突破 4–6
DFlash 块扩散草稿（角色反转）
双向注意力块扩散去噪器
单步并行生成 b=16 草稿词元
把串行小矩阵转为并行块矩阵
直接对齐 Tensor Core 高吞吐
自回归主干一次前向并行验证
严格保持目标分布无损输出
扩散做草稿 + 自回归做验证