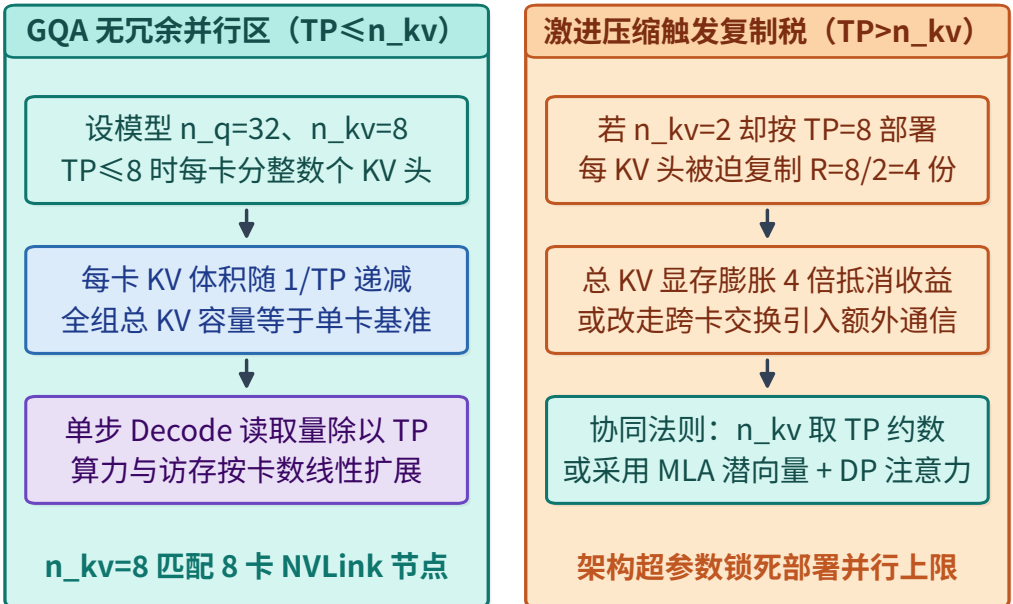
GQA 无冗余并行区（TP≤n_kv）
设模型 n_q=32、n_kv=8
TP≤8 时每卡分整数个 KV 头
每卡 KV 体积随 1/TP 递减
全组总 KV 容量等于单卡基准
单步 Decode 读取量除以 TP
算力与访存按卡数线性扩展
n_kv=8 匹配 8 卡 NVLink 节点
激进压缩触发复制税（TP>n_kv）
若 n_kv=2 却按 TP=8 部署
每 KV 头被迫复制 R=8/2=4 份
总 KV 显存膨胀 4 倍抵消收益
或改走跨卡交换引入额外通信
协同法则：n_kv 取 TP 约数
或采用 MLA 潜向量 + DP 注意力
架构超参数锁死部署并行上限