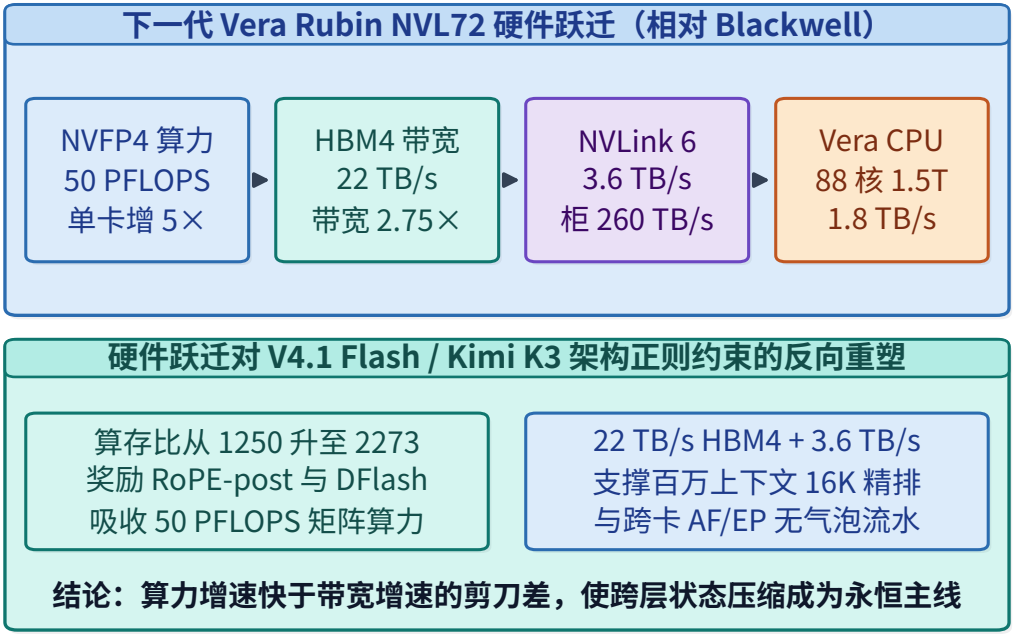
下一代 Vera Rubin NVL72 硬件跃迁（相对 Blackwell）
NVFP4 算力
50 PFLOPS
单卡增 5×
HBM4 带宽
22 TB/s
带宽 2.75×
NVLink 6
3.6 TB/s
柜 260 TB/s
Vera CPU
88 核 1.5T
1.8 TB/s
硬件跃迁对 V4.1 Flash / Kimi K3 架构正则约束的反向重塑
算存比从 1250 升至 2273
奖励 RoPE-post 与 DFlash
吸收 50 PFLOPS 矩阵算力
22 TB/s HBM4 + 3.6 TB/s
支撑百万上下文 16K 精排
与跨卡 AF/EP 无气泡流水
结论：算力增速快于带宽增速的剪刀差，使跨层状态压缩成为永恒主线