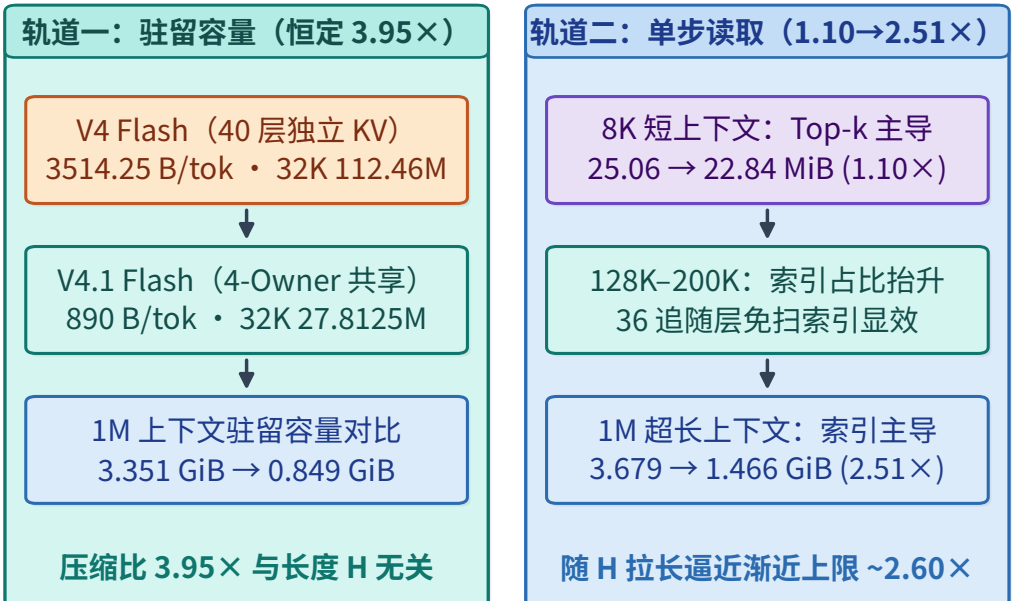
轨道一：驻留容量（恒定 3.95×）
V4 Flash（40 层独立 KV）
3514.25 B/tok · 32K 112.46M
V4.1 Flash（4-Owner 共享）
890 B/tok · 32K 27.8125M
1M 上下文驻留容量对比
3.351 GiB → 0.849 GiB
压缩比 3.95× 与长度 H 无关
轨道二：单步读取（1.10→2.51×）
8K 短上下文：Top-k 主导
25.06 → 22.84 MiB (1.10×)
128K–200K：索引占比抬升
36 追随层免扫索引显效
1M 超长上下文：索引主导
3.679 → 1.466 GiB (2.51×)
随 H 拉长逼近渐近上限 ~2.60×