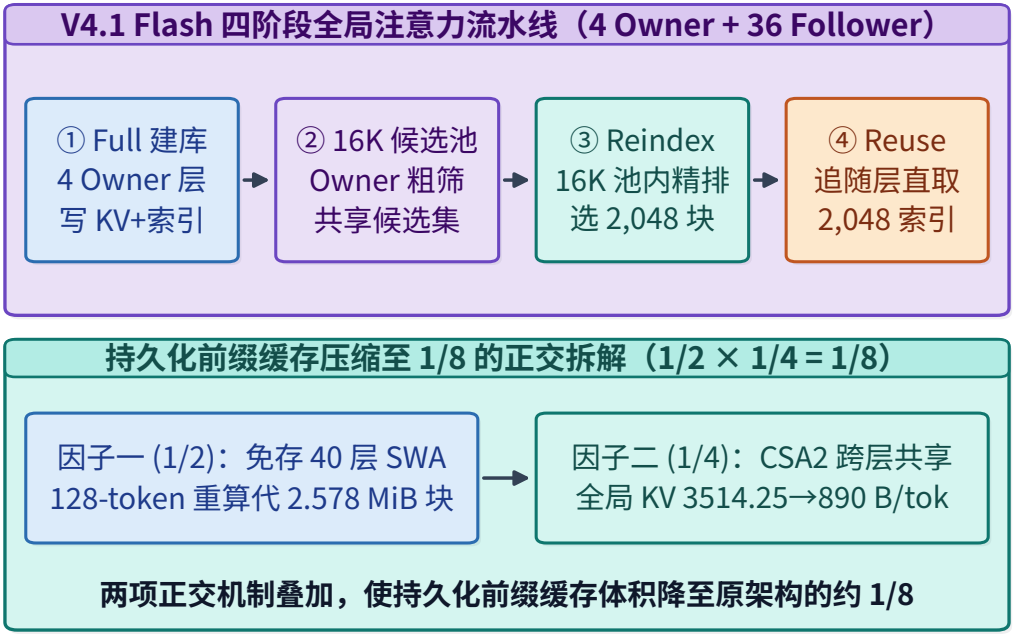
V4.1 Flash 四阶段全局注意力流水线（4 Owner + 36 Follower）
① Full 建库
4 Owner 层
写 KV+索引
② 16K 候选池
Owner 粗筛
共享候选集
③ Reindex
16K 池内精排
选 2,048 块
④ Reuse
追随层直取
2,048 索引
持久化前缀缓存压缩至 1/8 的正交拆解（1/2 × 1/4 = 1/8）
因子一 (1/2)：免存 40 层 SWA
128-token 重算代 2.578 MiB 块
因子二 (1/4)：CSA2 跨层共享
全局 KV 3514.25→890 B/tok
两项正交机制叠加，使持久化前缀缓存体积降至原架构的约 1/8