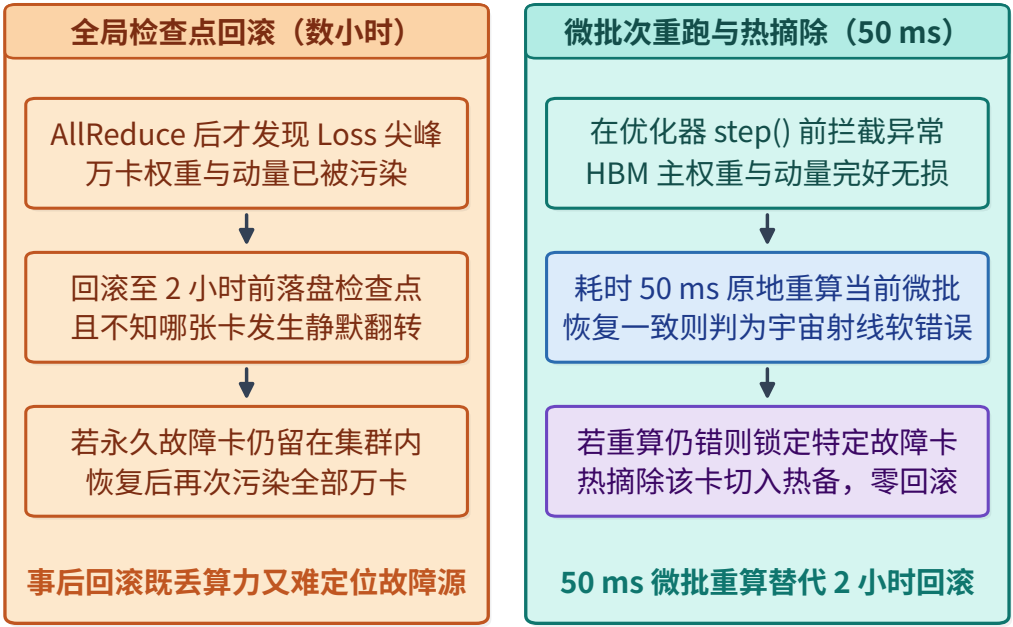
全局检查点回滚（数小时）
AllReduce 后才发现 Loss 尖峰
万卡权重与动量已被污染
回滚至 2 小时前落盘检查点
且不知哪张卡发生静默翻转
若永久故障卡仍留在集群内
恢复后再次污染全部万卡
事后回滚既丢算力又难定位故障源
微批次重跑与热摘除（50 ms）
在优化器 step() 前拦截异常
HBM 主权重与动量完好无损
耗时 50 ms 原地重算当前微批
恢复一致则判为宇宙射线软错误
若重算仍错则锁定特定故障卡
热摘除该卡切入热备，零回滚
50 ms 微批重算替代 2 小时回滚