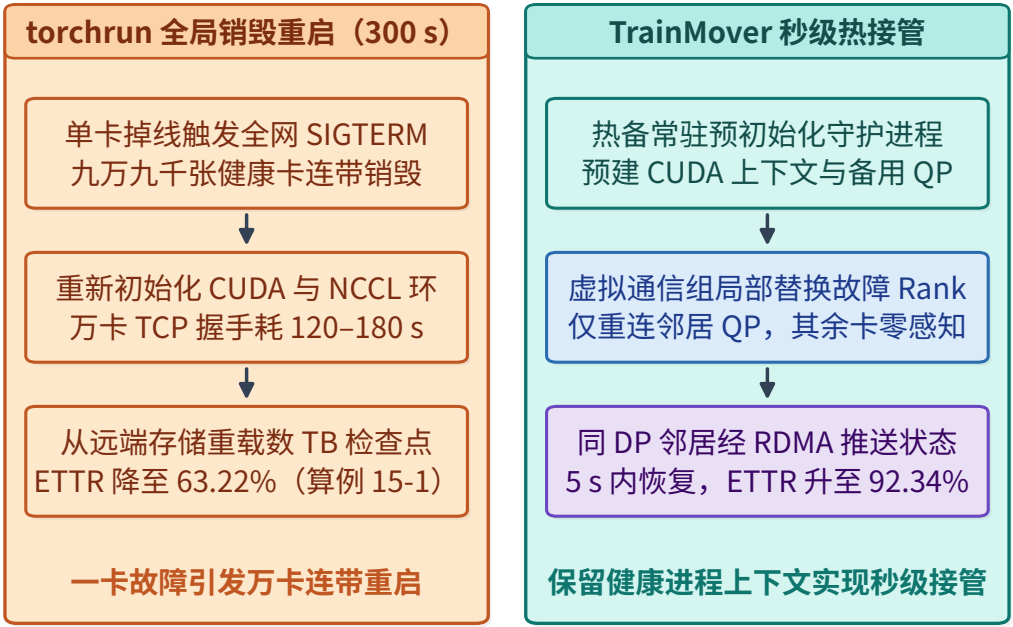
torchrun 全局销毁重启（300 s）
单卡掉线触发全网 SIGTERM
九万九千张健康卡连带销毁
重新初始化 CUDA 与 NCCL 环
万卡 TCP 握手耗 120–180 s
从远端存储重载数 TB 检查点
ETTR 降至 63.22%（算例 15-1）
一卡故障引发万卡连带重启
TrainMover 秒级热接管
热备常驻预初始化守护进程
预建 CUDA 上下文与备用 QP
虚拟通信组局部替换故障 Rank
仅重连邻居 QP，其余卡零感知
同 DP 邻居经 RDMA 推送状态
5 s 内恢复，ETTR 升至 92.34%
保留健康进程上下文实现秒级接管