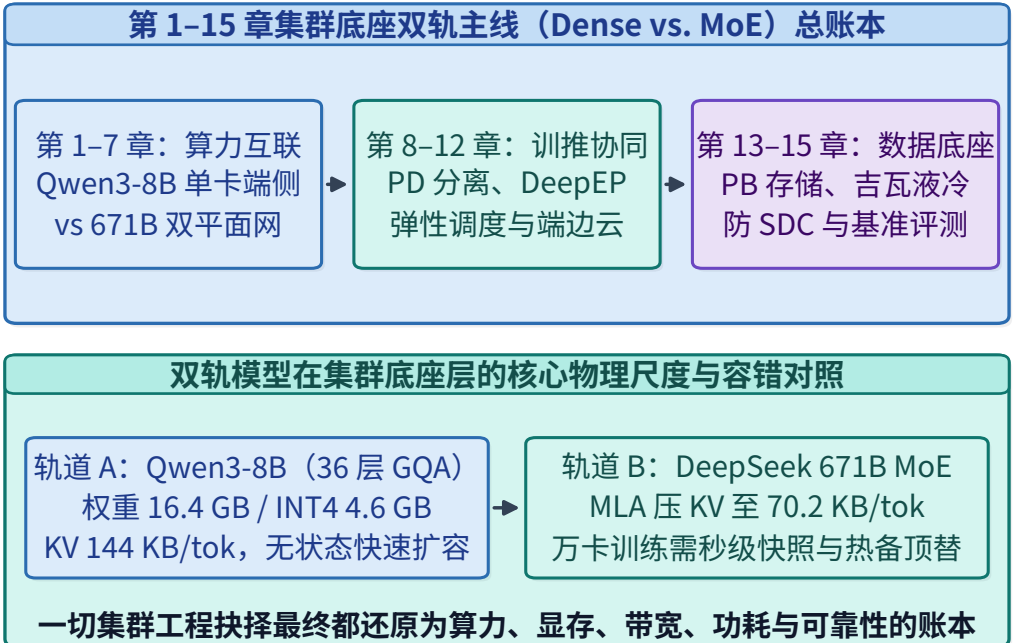
第 1–15 章集群底座双轨主线（Dense vs. MoE）总账本
第 1–7 章：算力互联
Qwen3-8B 单卡端侧
vs 671B 双平面网
第 8–12 章：训推协同
PD 分离、DeepEP
弹性调度与端边云
第 13–15 章：数据底座
PB 存储、吉瓦液冷
防 SDC 与基准评测
双轨模型在集群底座层的核心物理尺度与容错对照
轨道 A：Qwen3-8B（36 层 GQA）
权重 16.4 GB / INT4 4.6 GB
KV 144 KB/tok，无状态快速扩容
轨道 B：DeepSeek 671B MoE
MLA 压 KV 至 70.2 KB/tok
万卡训练需秒级快照与热备顶替
一切集群工程抉择最终都还原为算力、显存、带宽、功耗与可靠性的账本