残差流原位稀疏自编码器（SAE）特征监控与正交投影钳位

① 抽取残差流激活
定位关键安全层 h_l
零额外显存拷贝

② 单概念探测点积
<h_l, v_harm> 判别
单层仅耗 3.6 us

③ 正交子空间投影
减去有害方向分量
总开销仅 0.08%

外挂独立护栏模型 vs. 残差流内部表示工程（RepE）原位免疫

纯外部黑盒文本审查的局限性：
Base64 编码或隐喻越狱易绕过表层
且发现违规时已消耗主模型算力

白盒激活空间概念探针与钳位：
无论表层如何伪装均触发内部特征
原位抹除有害分量引导安全续写

在 Transformer 残差流内部以 3.6 us/层代价实现零延迟原位概念级免疫