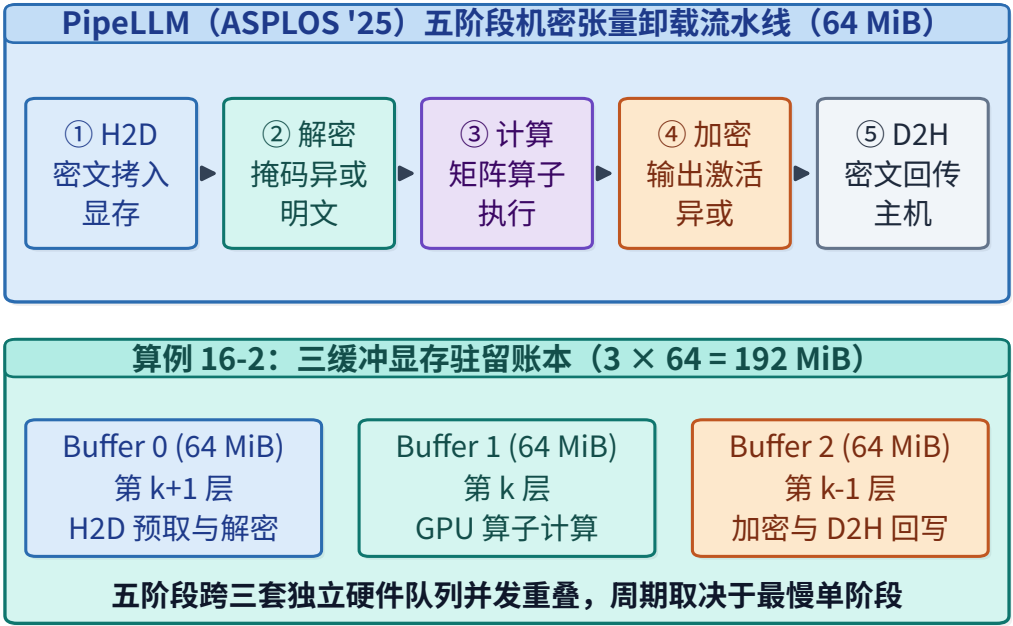
PipeLLM（ASPLOS '25）五阶段机密张量卸载流水线（64 MiB）
① H2D
密文拷入
显存
② 解密
掩码异或
明文
③ 计算
矩阵算子
执行
④ 加密
输出激活
异或
⑤ D2H
密文回传
主机
算例 16-2：三缓冲显存驻留账本（3 × 64 = 192 MiB）
Buffer 0 (64 MiB)
第 k+1 层
H2D 预取与解密
Buffer 1 (64 MiB)
第 k 层
GPU 算子计算
Buffer 2 (64 MiB)
第 k-1 层
加密与 D2H 回写
五阶段跨三套独立硬件队列并发重叠，周期取决于最慢单阶段