多维有害子空间（k=8 正交基）Householder 投影与正常语义保持

① 构建对比激活集
SVD 提取主成分基
U_harm 正交矩阵

② 单边 ReLU 门控
仅当投影为正才触发
正常请求零改动

③ 正交补空间保持
余弦相似度 >0.998
零拒答率攀升

粗暴全局激活截断（过度拒答）vs. 单边正交子空间精准切除

无门控全局方向减法的副作用：
良性医学或安全科普也被误伤扭曲
导致模型正常任务准确率下降

条件激活门控 + 正交投影矩阵：
与有害基正交的 8184 维完全无损
精准剥离越狱意图不伤推理能力

依托高维空间正交性，在 8192 维残差流中精准切除 8 维风险子空间