在线安全护栏架构：串行阻塞（+225 ms）vs. 异步伴飞（3.2 ms）

① 传统串行护栏墙
输入挡 45ms TTFT
输出挡 180ms 尾包

② 异步流式伴飞器
主模型零等待生成
同卡 MIG 旁路审查

③ K=8 投机窗口
单次审查 3.2 ms
暴露延迟 < 3.5 ms

为什么不能把 8B 安全分类器直接串联在 70B 主模型推理链路中?

串行护栏的延迟与吞吐双重代价：
首词元延迟翻倍且破坏流式体验
尾包整句复审导致长文本严重卡顿

双流异步伴飞投机审查架构：
99.5% 正常请求享受零阻塞下发
仅在末块承担 3.2 ms 轻量级确认

将串行关卡重构为异步旁路伴飞，把护栏暴露延迟从 225 ms 压至 3.2 ms