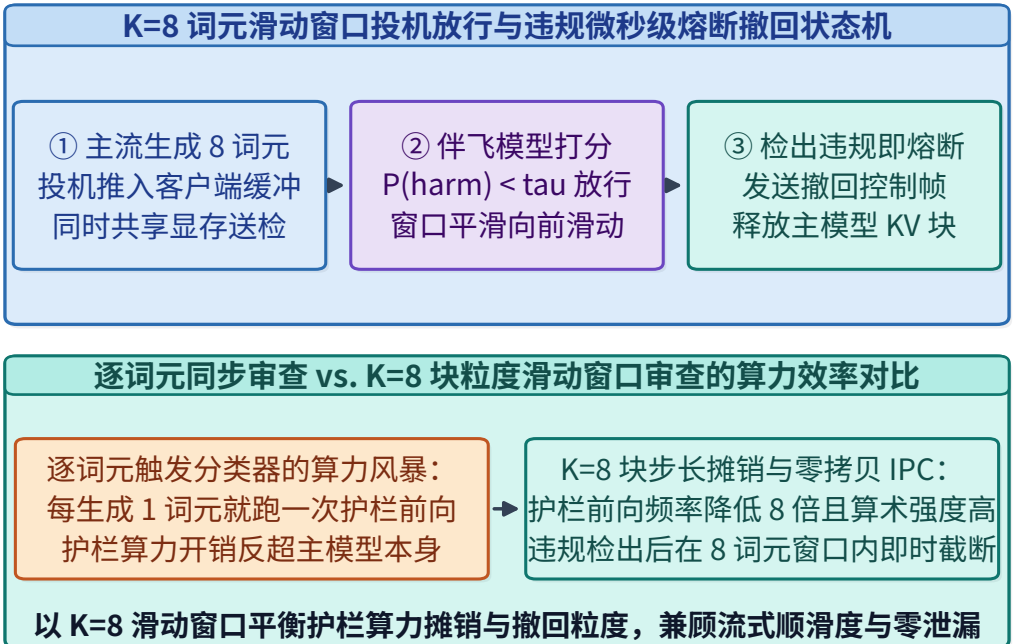
K=8 词元滑动窗口投机放行与违规微秒级熔断撤回状态机
① 主流生成 8 词元
投机推入客户端缓冲
同时共享显存送检
② 伴飞模型打分
P(harm) < tau 放行
窗口平滑向前滑动
③ 检出违规即熔断
发送撤回控制帧
释放主模型 KV 块
逐词元同步审查 vs. K=8 块粒度滑动窗口审查的算力效率对比
逐词元触发分类器的算力风暴：
每生成 1 词元就跑一次护栏前向
护栏算力开销反超主模型本身
K=8 块步长摊销与零拷贝 IPC：
护栏前向频率降低 8 倍且算术强度高
违规检出后在 8 词元窗口内即时截断
以 K=8 滑动窗口平衡护栏算力摊销与撤回粒度，兼顾流式顺滑度与零泄漏