跨洲际训练 70B：标准 AllReduce（700G）vs. DiLoCo 双层优化器

① 跨洲每步同步瓶颈
2.4s 传 210 GB
需 700 Gbps 专线

② 本地内循环 AdamW
独立自治 H=500 步
历时 20 分钟零外网

③ 外循环 Nesterov
聚合伪梯度 Delta
通信频率降 500x

为什么单层同步 SGD/AdamW 无法跨越广域网（RTT=85 ms）？

广域网高延迟与低带宽约束：
每步 Barrier 等待 85 ms 光纤往返
百 Gbps 跨洋专线造价极其高昂

双层优化器解耦（Inner/Outer）：
内循环利用机房内 NVLink 高速收敛
外循环将 500 步轨迹缩为单次同步

本地 H=500 步 AdamW 叠外循环 Nesterov 动量，跨区通信降 500 倍