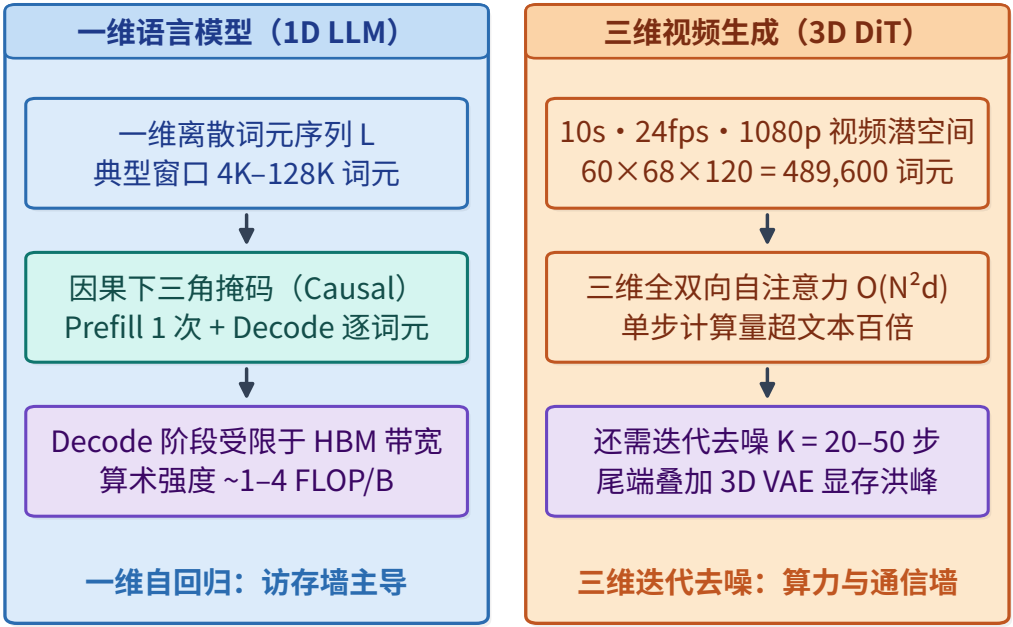
一维语言模型（1D LLM）
一维离散词元序列 L
典型窗口 4K–128K 词元
因果下三角掩码（Causal）
Prefill 1 次 + Decode 逐词元
Decode 阶段受限于 HBM 带宽
算术强度 ~1–4 FLOP/B
一维自回归：访存墙主导
三维视频生成（3D DiT）
10s・24fps・1080p 视频潜空间
60×68×120 = 489,600 词元
三维全双向自注意力 O(N²d)
单步计算量超文本百倍
还需迭代去噪 K = 20–50 步
尾端叠加 3D VAE 显存洪峰
三维迭代去噪：算力与通信墙