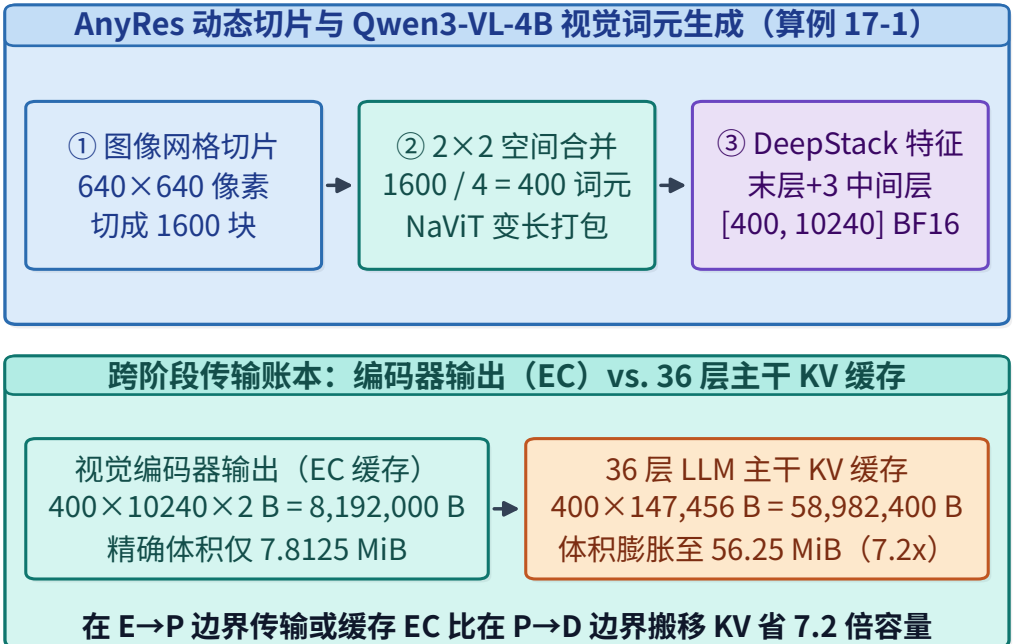
AnyRes 动态切片与 Qwen3-VL-4B 视觉词元生成（算例 17-1）
① 图像网格切片
640×640 像素
切成 1600 块
② 2×2 空间合并
1600 / 4 = 400 词元
NaViT 变长打包
③ DeepStack 特征
末层+3 中间层
[400, 10240] BF16
跨阶段传输账本：编码器输出（EC）vs. 36 层主干 KV 缓存
视觉编码器输出（EC 缓存）
400×10240×2 B = 8,192,000 B
精确体积仅 7.8125 MiB
36 层 LLM 主干 KV 缓存
400×147,456 B = 58,982,400 B
体积膨胀至 56.25 MiB（7.2x）
在 E→P 边界传输或缓存 EC 比在 P→D 边界搬移 KV 省 7.2 倍容量