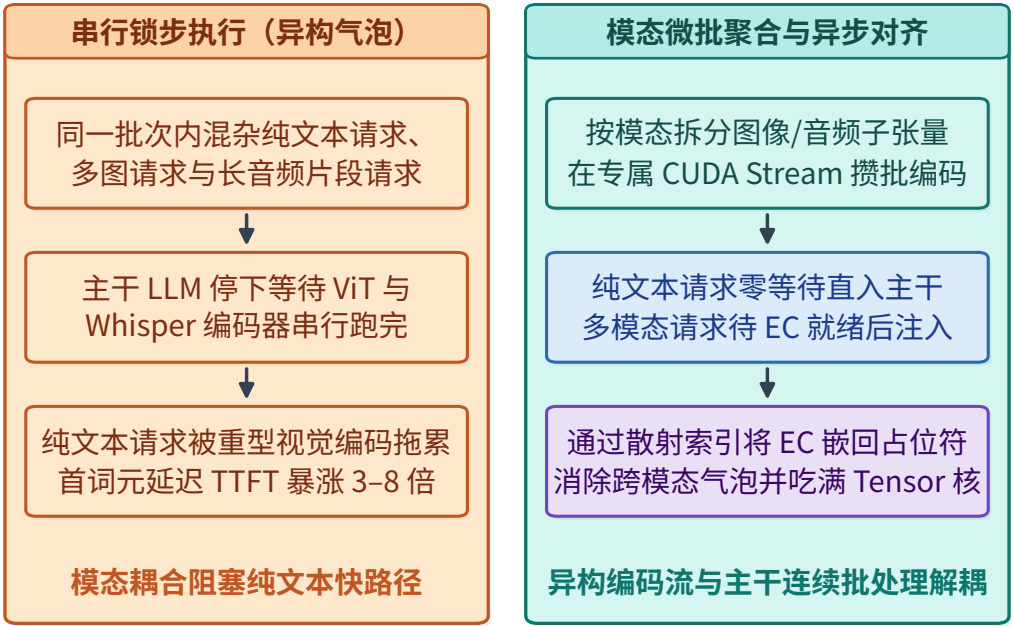
串行锁步执行（异构气泡）
同一批次内混杂纯文本请求、多图请求与长音频片段请求
主干 LLM 停下等待 ViT 与 Whisper 编码器串行跑完
纯文本请求被重型视觉编码拖累首词元延迟 TTFT 暴涨 3–8 倍
模态耦合阻塞纯文本快路径
模态微批聚合与异步对齐
按模态拆分图像/音频子张量在专属 CUDA Stream 攒批编码
纯文本请求零等待直入主干多模态请求待 EC 就绪后注入
通过散射索引将 EC 嵌回占位符消除跨模态气泡并吃满 Tensor 核
异构编码流与主干连续批处理解耦