交互式世界模型（StreamDiffusionV2 / CausVid）30 FPS 实时流水

① 因果自回归改造
块级因果注意力
按帧块流式吐出

→

② 分布匹配蒸馏
50 步浓缩为 1–4 步
砍掉 CFG 双倍分支

→

③ 滚动 KV 缓存池
固定窗口复用历史帧
淘汰过期帧防溢出

步间小批次流水（Stream Batching）：在 33.3 ms 红线内响应动作

传统整段双向扩散
必须等 240 帧全部去噪 50 步
首帧响应延迟 > 30,000 ms

→

4 步因果流式 + 跨帧去噪步拼批
4 个相邻帧分处去噪步 s=4,3,2,1
每 ⩽ 33.3 ms 稳定输出 1 帧新画面

用因果块注意力 + 滚动 KV + 4 步流式拼批跨越实时交互生死线