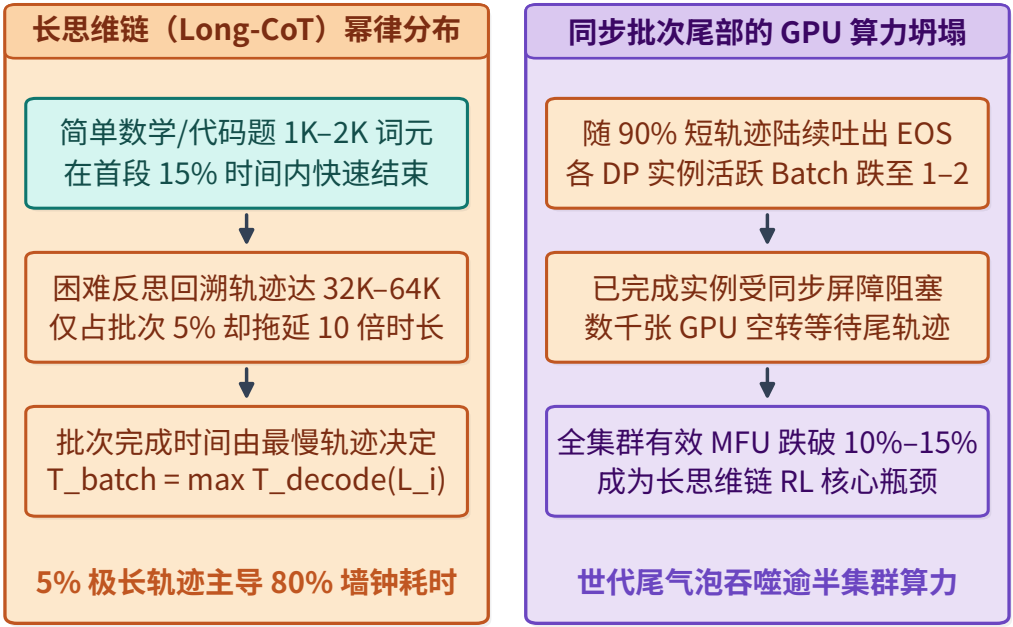
长思维链（Long-CoT）幂律分布
简单数学/代码题 1K–2K 词元
在首段 15% 时间内快速结束
困难反思回溯轨迹达 32K–64K
仅占批次 5% 却拖延 10 倍时长
批次完成时间由最慢轨迹决定
T_batch = max T_decode(L_i)
5% 极长轨迹主导 80% 墙钟耗时
同步批次尾部的 GPU 算力坍塌
随 90% 短轨迹陆续吐出 EOS
各 DP 实例活跃 Batch 跌至 1–2
已完成实例受同步屏障阻塞
数千张 GPU 空转等待尾轨迹
全集群有效 MFU 跌破 10%–15%
成为长思维链 RL 核心瓶颈
世代尾气泡吞噬逾半集群算力