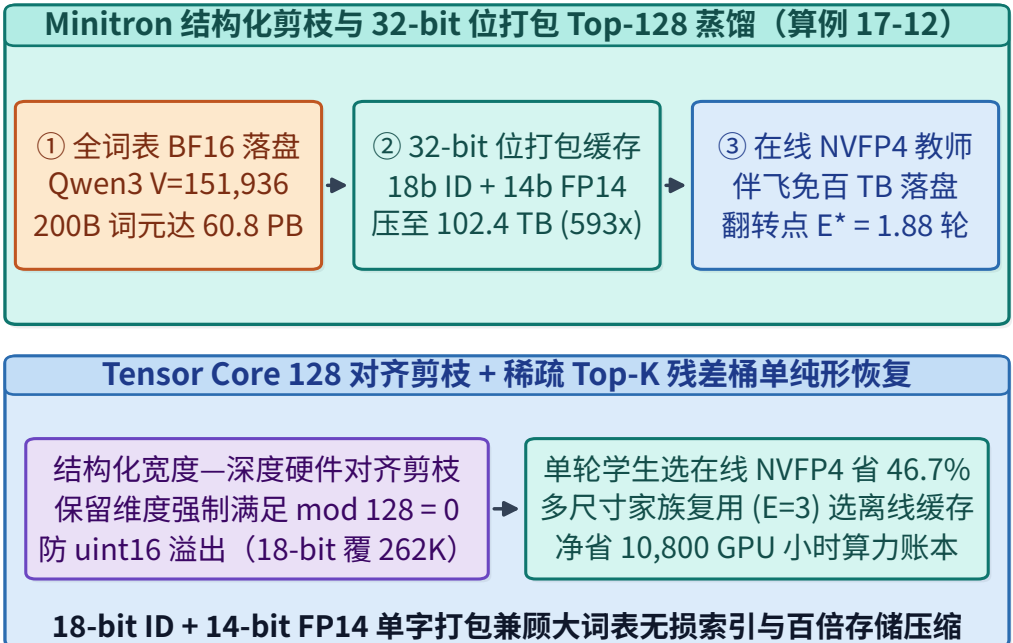
Minitron 结构化剪枝与 32-bit 位打包 Top-128 蒸馏（算例 17-12）
① 全词表 BF16 落盘
Qwen3 V=151,936
200B 词元达 60.8 PB
② 32-bit 位打包缓存
18b ID + 14b FP14
压至 102.4 TB (593x)
③ 在线 NVFP4 教师
伴飞免百 TB 落盘
翻转点 E* = 1.88 轮
Tensor Core 128 对齐剪枝 + 稀疏 Top-K 残差桶单纯形恢复
结构化宽度—深度硬件对齐剪枝
保留维度强制满足 mod 128 = 0
防 uint16 溢出（18-bit 覆 262K）
单轮学生选在线 NVFP4 省 46.7%
多尺寸家族复用 (E=3) 选离线缓存
净省 10,800 GPU 小时算力账本
18-bit ID + 14-bit FP14 单字打包兼顾大词表无损索引与百倍存储压缩