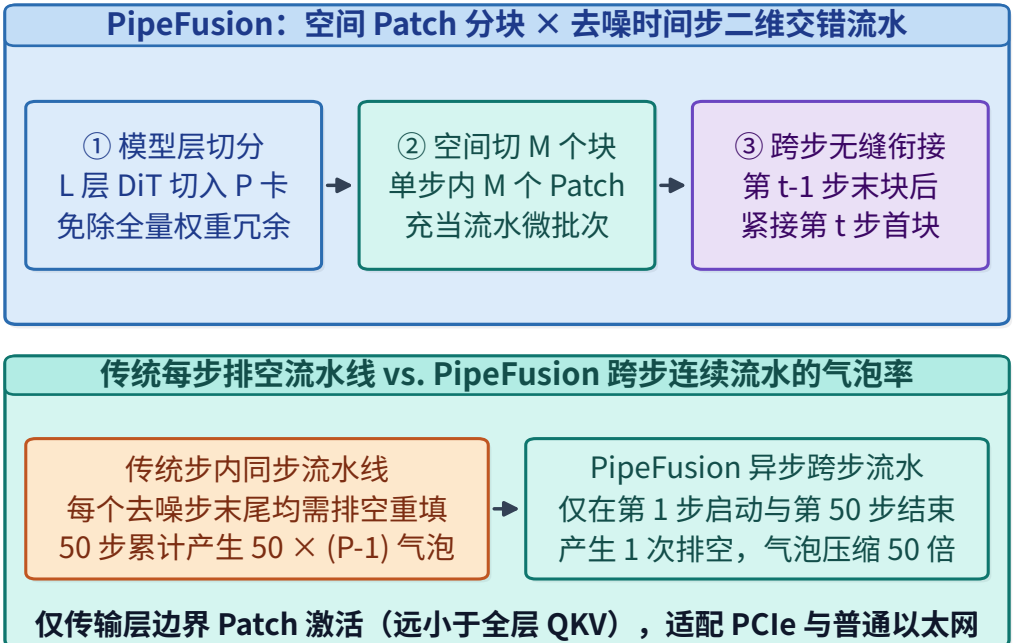
PipeFusion：空间 Patch 分块 × 去噪时间步二维交错流水
① 模型层切分
L 层 DiT 切入 P 卡
免除全量权重冗余
② 空间切 M 个块
单步内 M 个 Patch
充当流水微批次
③ 跨步无缝衔接
第 t-1 步末块后
紧接第 t 步首块
传统每步排空流水线 vs. PipeFusion 跨步连续流水的气泡率
传统步内同步流水线
每个去噪步末尾均需排空重填
50 步累计产生 50 × (P-1) 气泡
PipeFusion 异步跨步流水
仅在第 1 步启动与第 50 步结束
产生 1 次排空，气泡压缩 50 倍
仅传输层边界 Patch 激活（远小于全层 QKV），适配 PCIe 与普通以太网