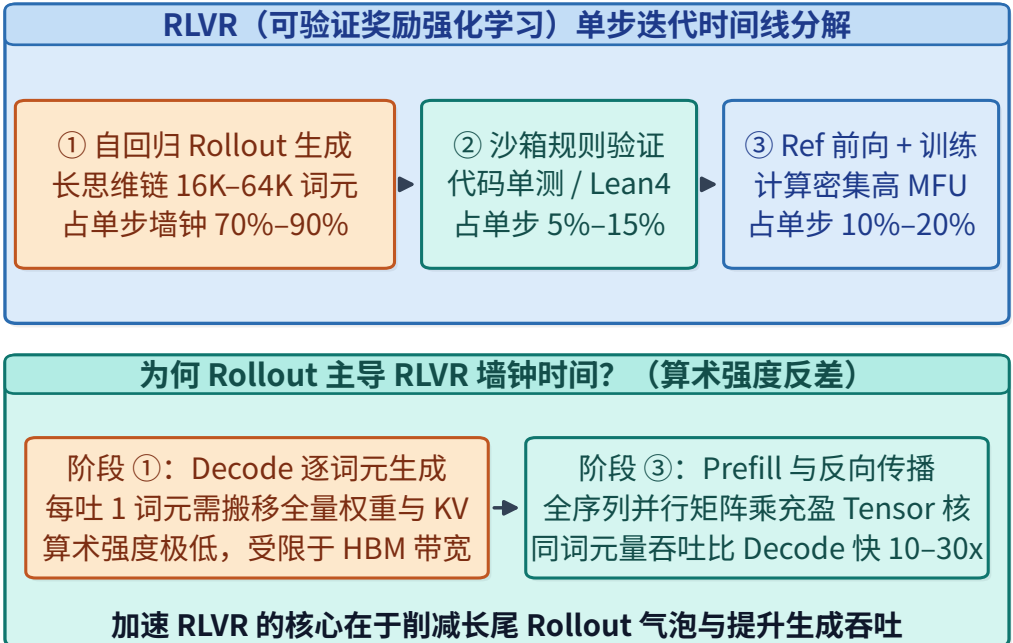
RLVR（可验证奖励强化学习）单步迭代时间线分解
① 自回归 Rollout 生成
长思维链 16K–64K 词元
占单步墙钟 70%–90%
② 沙箱规则验证
代码单测 / Lean4
占单步 5%–15%
③ Ref 前向 + 训练
计算密集高 MFU
占单步 10%–20%
为何 Rollout 主导 RLVR 墙钟时间？（算术强度反差）
阶段 ①：Decode 逐词元生成
每吐 1 词元需搬移全量权重与 KV
算术强度极低，受限于 HBM 带宽
阶段 ③：Prefill 与反向传播
全序列并行矩阵乘充盈 Tensor 核
同词元量吞吐比 Decode 快 10–30x
加速 RLVR 的核心在于削减长尾 Rollout 气泡与提升生成吞吐