Seer（OSDI 26）：分而治之上下文缓存与组内同源投机解码

① 细粒度分段生成
长轨迹按固定块切分
均衡各卡 KV 占用

→

② 组内后缀字典树
同提示词已完短轨迹
构建免模型草稿树

→

③ 尾部自适应投机
对剩余长尾轨迹开启
多步树验证加速吐词

利用 GRPO 组采样（G=8–64）天然同源性实现零额外显存投机加速

传统独立草稿模型投机
需额外部署并同步训练 Draft 模型
初期大 Batch 下反而拖慢吞吐

→

Seer / DAS 自适应尾部投机
仅在尾部小 Batch 期启用组内草稿
长尾生成延迟削减 40%–60%

利用同组兄弟轨迹的高重合步骤，为尾部 5% 慢轨迹提供免模型草稿