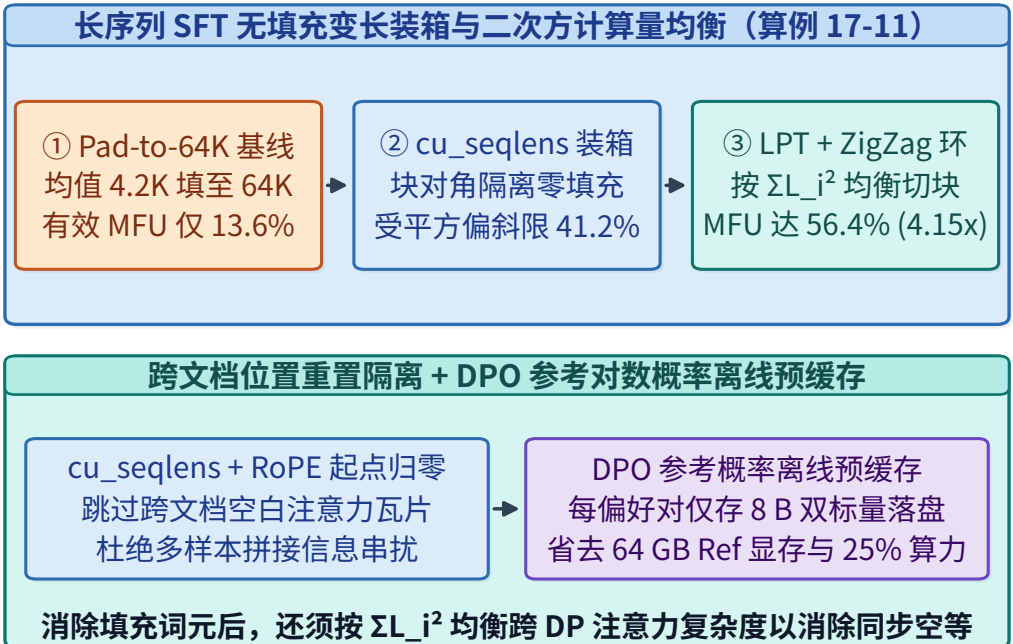
长序列 SFT 无填充变长装箱与二次方计算量均衡（算例 17-11）
① Pad-to-64K 基线
均值 4.2K 填至 64K
有效 MFU 仅 13.6%
② cu_seqlens 装箱
块对角隔离零填充
受平方偏斜限 41.2%
③ LPT + ZigZag 环
按 ΣL_i² 均衡切块
MFU 达 56.4% (4.15x)
跨文档位置重置隔离 + DPO 参考对数概率离线预缓存
cu_seqlens + RoPE 起点归零
跳过跨文档空白注意力瓦片
杜绝多样本拼接信息串扰
DPO 参考概率离线预缓存
每偏好对仅存 8 B 双标量落盘
省去 64 GB Ref 显存与 25% 算力
消除填充词元后，还须按 ΣL_i² 均衡跨 DP 注意力复杂度以消除同步空等