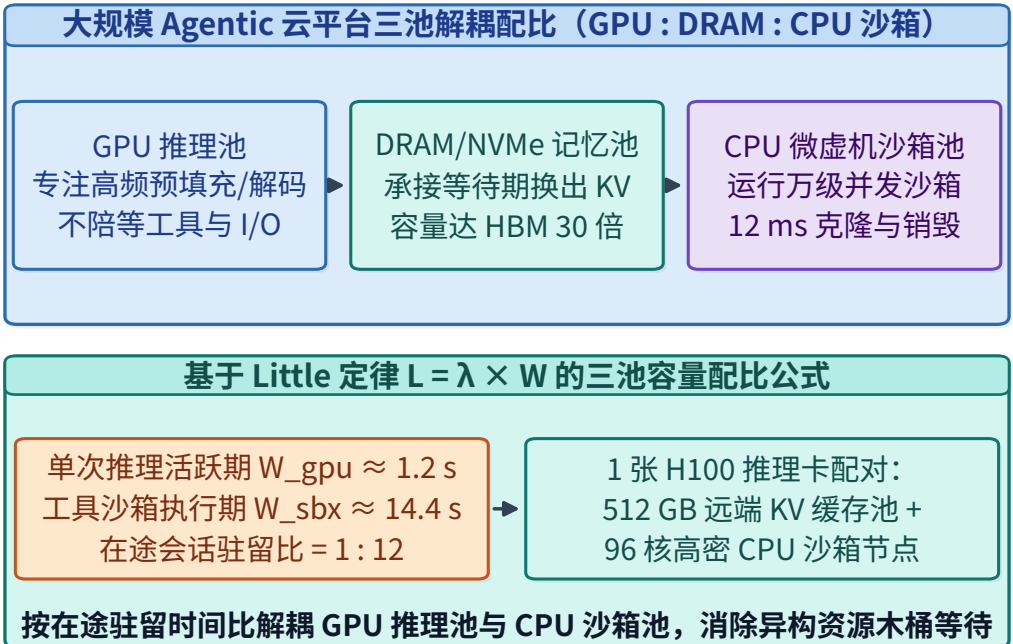
大规模 Agentic 云平台三池解耦配比（GPU : DRAM : CPU 沙箱）
GPU 推理池
专注高频预填充/解码
不陪等工具与 I/O
DRAM/NVMe 记忆池
承接等待期换出 KV
容量达 HBM 30 倍
CPU 微虚机沙箱池
运行万级并发沙箱
12 ms 克隆与销毁
基于 Little 定律 L = λ × W 的三池容量配比公式
单次推理活跃期 W_gpu ≈ 1.2 s
工具沙箱执行期 W_sbx ≈ 14.4 s
在途会话驻留比 = 1 : 12
1 张 H100 推理卡配对：
512 GB 远端 KV 缓存池 +
96 核高密 CPU 沙箱节点
按在途驻留时间比解耦 GPU 推理池与 CPU 沙箱池，消除异构资源木桶等待