## CacheGen 锚点差分量化与算术熵编码流式传输（算例 18-2）

① 锚点帧残差差分
利用相邻词元高余弦相似
提取层内局部残差 ΔK, ΔV

→

② 分层量化 + 算术编码
浅层高精度、深层紧凑量化
16-bit 压至 3.80 bits（4.21×）

## 50 Gbps（5.81 GiB/s）跨机架网络传输 vs. 本地重算回本线

原始 9.00 GiB KV 跨网传输
耗时 1,549.1 ms > 重算 500 ms
受制于 18 GiB/s 临界带宽墙

→

CacheGen 压缩至 2.1375 GiB
传输 367.9 ms + 解压 18.0 ms
总计 385.9 ms（快 4.01 倍）

**当跨机架带宽低于 18 GiB/s 时，必须结合流式熵编码才能击败重算**