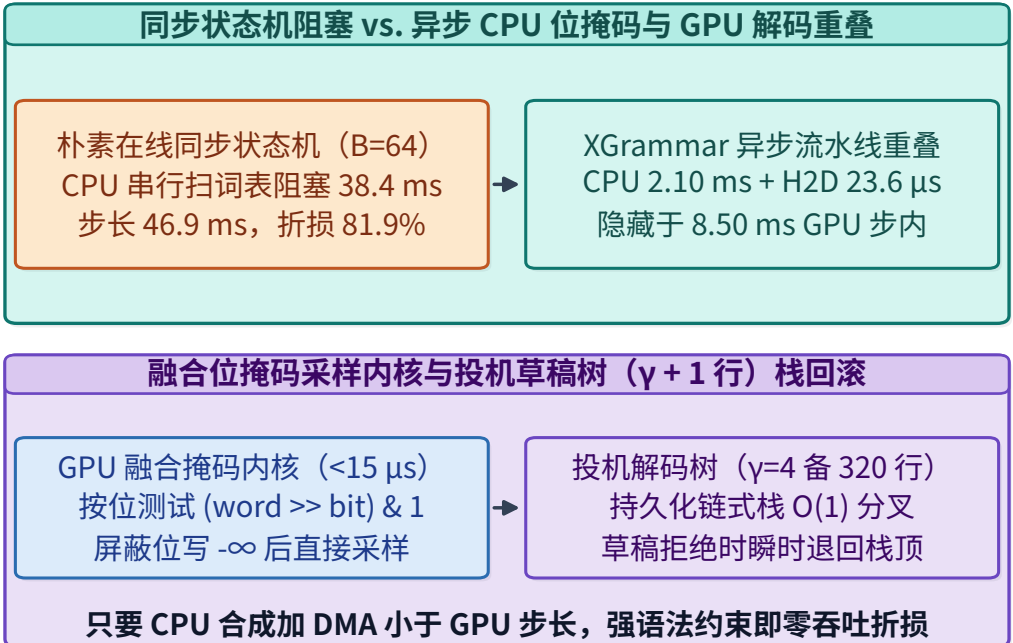
同步状态机阻塞 vs. 异步 CPU 位掩码与 GPU 解码重叠
朴素在线同步状态机（B=64）
CPU 串行扫词表阻塞 38.4 ms
步长 46.9 ms，折损 81.9%
XGrammar 异步流水线重叠
CPU 2.10 ms + H2D 23.6 µs
隐藏于 8.50 ms GPU 步内
融合位掩码采样内核与投机草稿树（γ + 1 行）栈回滚
GPU 融合掩码内核（<15 µs）
按位测试 (word >> bit) & 1
屏蔽位写 -∞ 后直接采样
投机解码树（γ=4 备 320 行）
持久化链式栈 O(1) 分叉
草稿拒绝时瞬时退回栈顶
只要 CPU 合成加 DMA 小于 GPU 步长，强语法约束即零吞吐折损