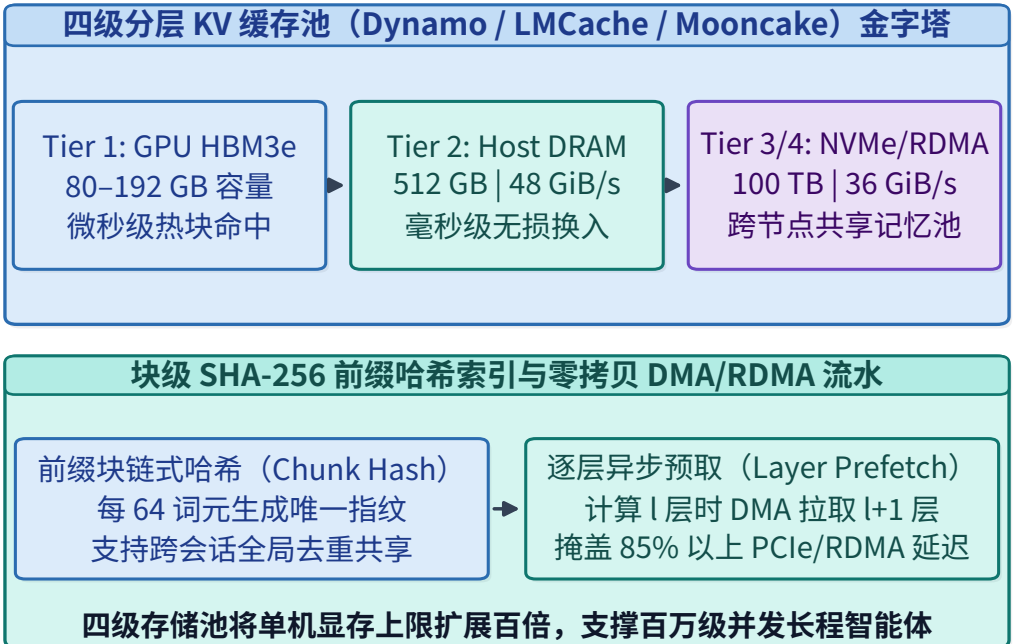
四级分层 KV 缓存池（Dynamo / LMCache / Mooncake）金字塔
Tier 1: GPU HBM3e
80–192 GB 容量
微秒级热块命中
Tier 2: Host DRAM
512 GB | 48 GiB/s
毫秒级无损换入
Tier 3/4: NVMe/RDMA
100 TB | 36 GiB/s
跨节点共享记忆池
块级 SHA-256 前缀哈希索引与零拷贝 DMA/RDMA 流水
前缀块链式哈希（Chunk Hash）
每 64 词元生成唯一指纹
支持跨会话全局去重共享
逐层异步预取（Layer Prefetch）
计算 l 层时 DMA 拉取 l+1 层
掩盖 85% 以上 PCIe/RDMA 延迟
四级存储池将单机显存上限扩展百倍，支撑百万级并发长程智能体