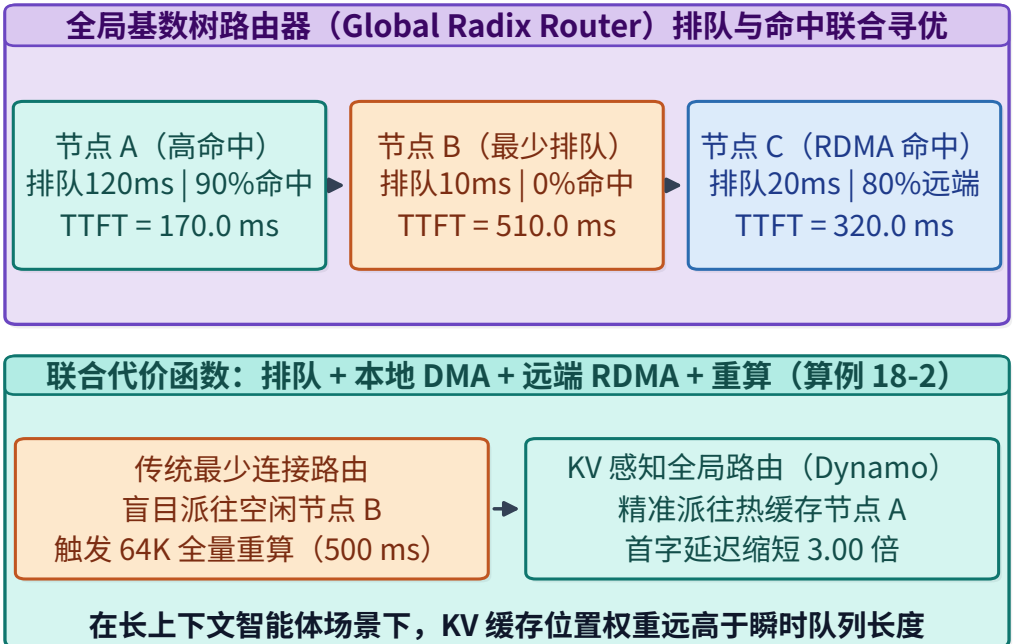
全局基数树路由器（Global Radix Router）排队与命中联合寻优
节点 A（高命中）
排队120ms | 90%命中
TTFT = 170.0 ms
节点 B（最少排队）
排队10ms | 0%命中
TTFT = 510.0 ms
节点 C（RDMA 命中）
排队20ms | 80%远端
TTFT = 320.0 ms
联合代价函数：排队 + 本地 DMA + 远端 RDMA + 重算（算例 18-2）
传统最少连接路由
盲目派往空闲节点 B
触发 64K 全量重算（500 ms）
KV 感知全局路由（Dynamo）
精准派往热缓存节点 A
首字延迟缩短 3.00 倍
在长上下文智能体场景下，KV 缓存位置权重远高于瞬时队列长度