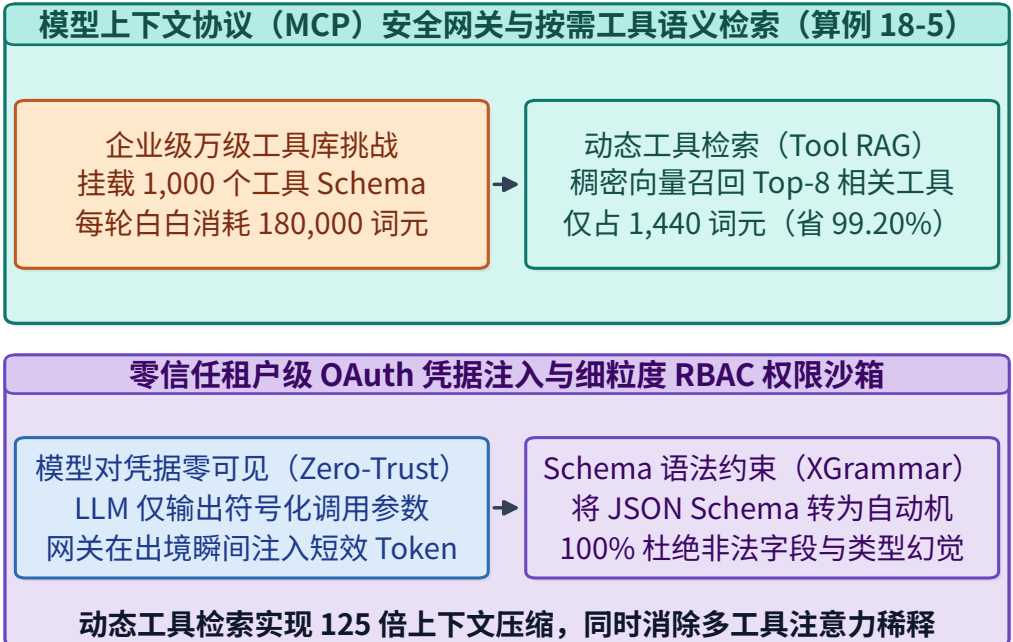
模型上下文协议（MCP）安全网关与按需工具语义检索（算例 18-5）
企业级万级工具库挑战
挂载 1,000 个工具 Schema
每轮白白消耗 180,000 词元
动态工具检索（Tool RAG）
稠密向量召回 Top-8 相关工具
仅占 1,440 词元（省 99.20%）
零信任租户级 OAuth 凭据注入与细粒度 RBAC 权限沙箱
模型对凭据零可见（Zero-Trust）
LLM 仅输出符号化调用参数
网关在出境瞬间注入短效 Token
Schema 语法约束（XGrammar）
将 JSON Schema 转为自动机
100% 杜绝非法字段与类型幻觉
动态工具检索实现 125 倍上下文压缩，同时消除多工具注意力稀释