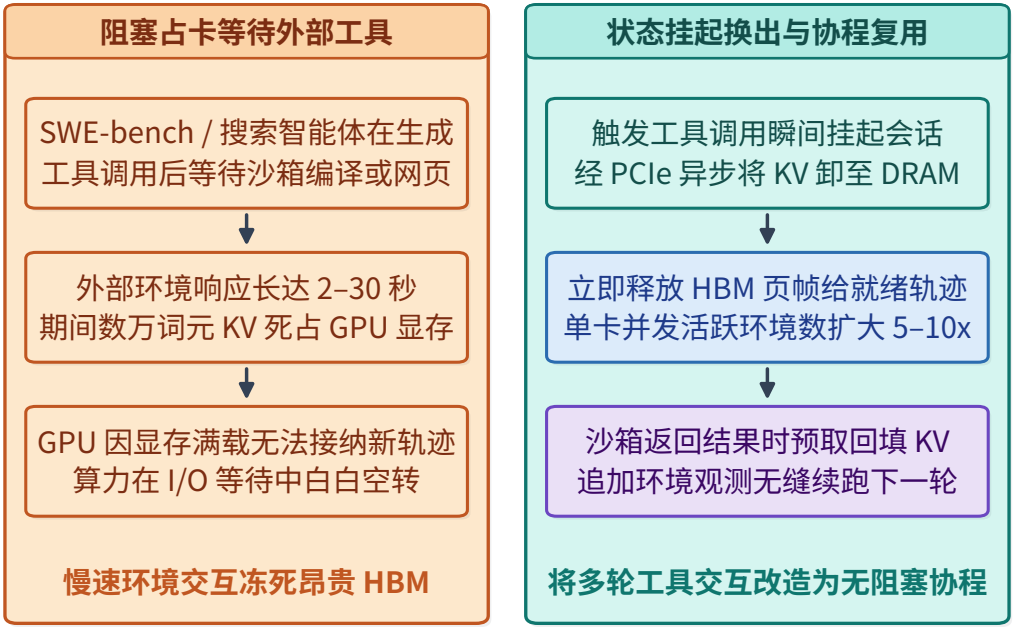
阻塞占卡等待外部工具
SWE-bench / 搜索智能体在生成
工具调用后等待沙箱编译或网页
外部环境响应长达 2–30 秒
期间数万词元 KV 死占 GPU 显存
GPU 因显存满载无法接纳新轨迹
算力在 I/O 等待中白白空转
慢速环境交互冻死昂贵 HBM
状态挂起换出与协程复用
触发工具调用瞬间挂起会话
经 PCIe 异步将 KV 卸至 DRAM
立即释放 HBM 页帧给就绪轨迹
单卡并发活跃环境数扩大 5–10x
沙箱返回结果时预取回填 KV
追加环境观测无缝续跑下一轮
将多轮工具交互改造为无阻塞协程