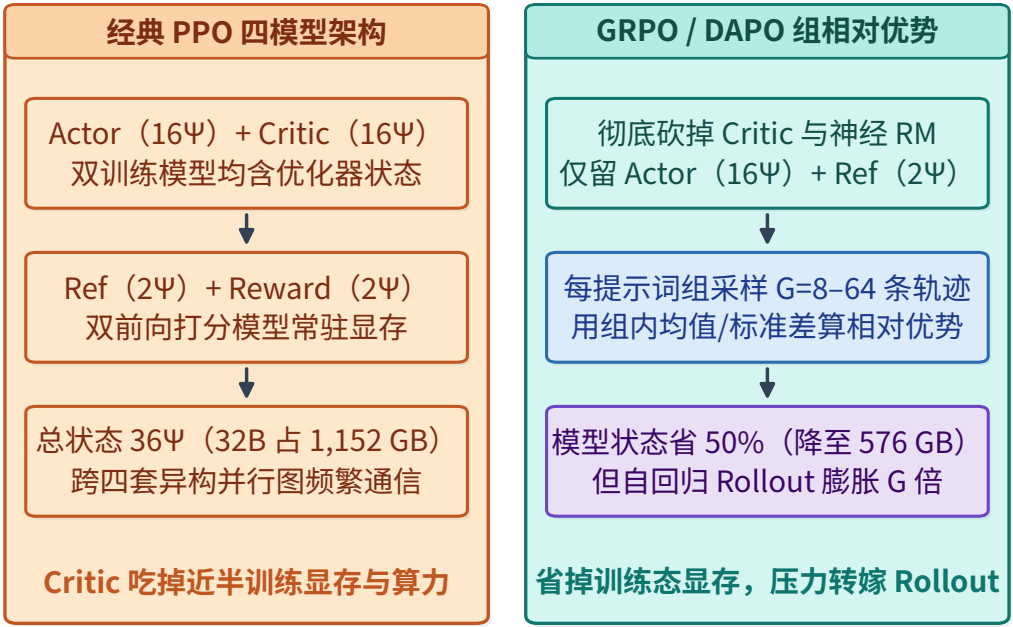
经典 PPO 四模型架构
Actor（16Ψ）+ Critic（16Ψ）
双训练模型均含优化器状态
Ref（2Ψ）+ Reward（2Ψ）
双前向打分模型常驻显存
总状态 36Ψ（32B 占 1,152 GB）
跨四套异构并行图频繁通信
Critic 吃掉近半训练显存与算力
GRPO / DAPO 组相对优势
彻底砍掉 Critic 与神经 RM
仅留 Actor（16Ψ）+ Ref（2Ψ）
每提示词组采样 G=8–64 条轨迹
用组内均值/标准差算相对优势
模型状态省 50%（降至 576 GB）
但自回归 Rollout 膨胀 G 倍
省掉训练态显存，压力转嫁 Rollout