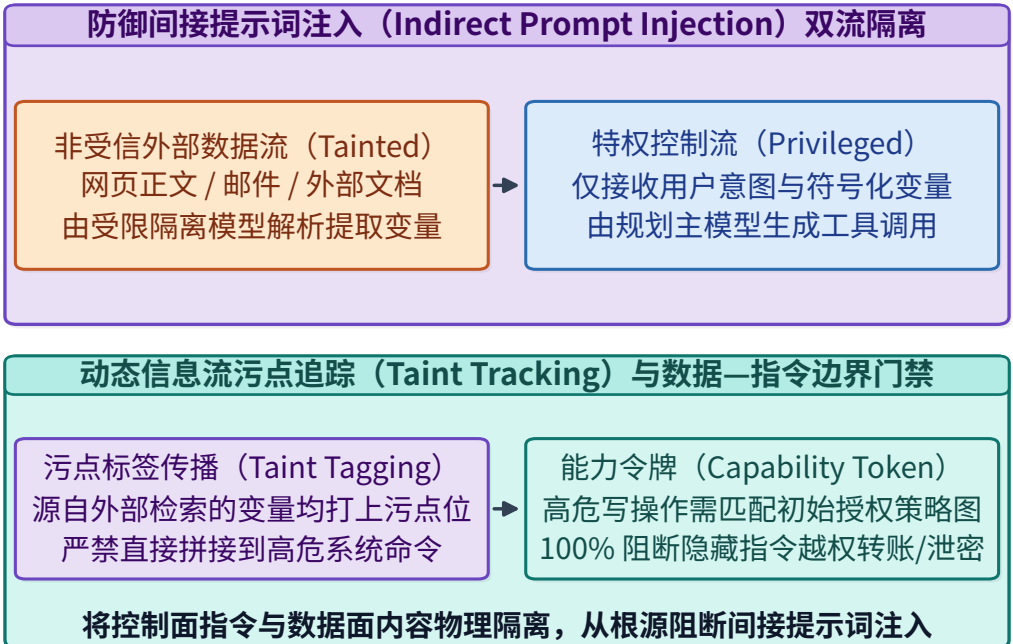
防御间接提示词注入（Indirect Prompt Injection）双流隔离
非受信外部数据流（Tainted）
网页正文 / 邮件 / 外部文档
由受限隔离模型解析提取变量
特权控制流（Privileged）
仅接收用户意图与符号化变量
由规划主模型生成工具调用
动态信息流污点追踪（Taint Tracking）与数据—指令边界门禁
污点标签传播（Taint Tagging）
源自外部检索的变量均打上污点位
严禁直接拼接到高危系统命令
能力令牌（Capability Token）
高危写操作需匹配初始授权策略图
100% 阻断隐藏指令越权转账/泄密
将控制面指令与数据面内容物理隔离，从根源阻断间接提示词注入