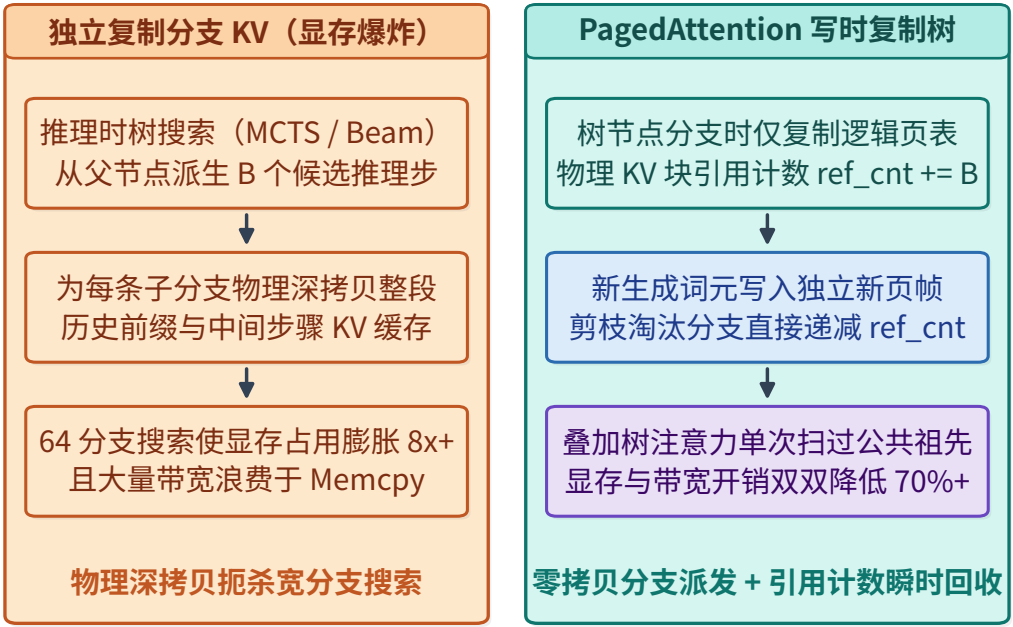
独立复制分支 KV（显存爆炸）
推理时树搜索（MCTS / Beam）
从父节点派生 B 个候选推理步
为每条子分支物理深拷贝整段
历史前缀与中间步骤 KV 缓存
64 分支搜索使显存占用膨胀 8x+
且大量带宽浪费于 Memcpy
物理深拷贝扼杀宽分支搜索
PagedAttention 写时复制树
树节点分支时仅复制逻辑页表
物理 KV 块引用计数 ref_cnt += B
新生成词元写入独立新页帧
剪枝淘汰分支直接递减 ref_cnt
叠加树注意力单次扫过公共祖先
显存与带宽开销双双降低 70%+
零拷贝分支派发 + 引用计数瞬时回收