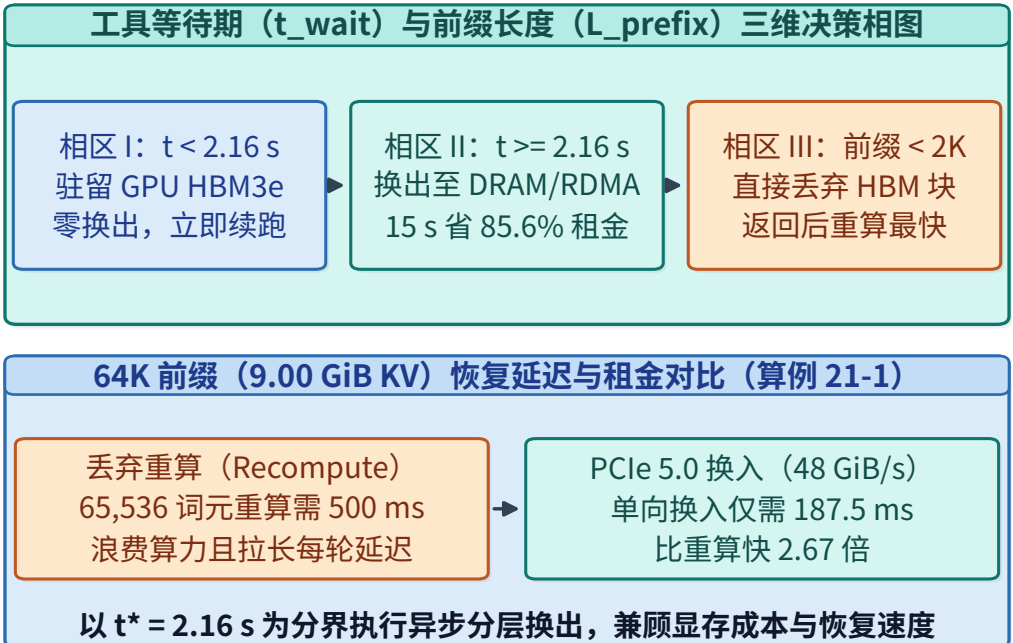
工具等待期（t_wait）与前缀长度（L_prefix）三维决策相图
相区 I：t < 2.16 s
驻留 GPU HBM3e
零换出，立即续跑
相区 II：t >= 2.16 s
换出至 DRAM/RDMA
15 s 省 85.6% 租金
相区 III：前缀 < 2K
直接丢弃 HBM 块
返回后重算最快
64K 前缀（9.00 GiB KV）恢复延迟与租金对比（算例 21-1）
丢弃重算（Recompute）
65,536 词元重算需 500 ms
浪费算力且拉长每轮延迟
PCIe 5.0 换入（48 GiB/s）
单向换入仅需 187.5 ms
比重算快 2.67 倍
以 t* = 2.16 s 为分界执行异步分层换出，兼顾显存成本与恢复速度