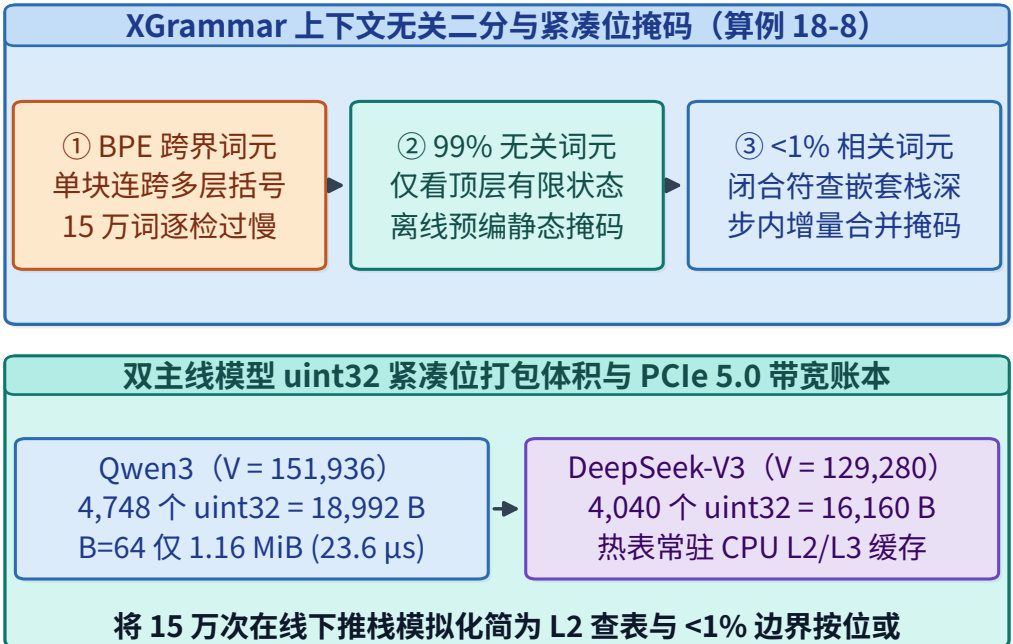
XGrammar 上下文无关二分与紧凑位掩码（算例 18-8）
① BPE 跨界词元
单块连跨多层括号
15 万词逐检过慢
② 99% 无关词元
仅看顶层有限状态
离线预编静态掩码
③ <1% 相关词元
闭合符查嵌套栈深
步内增量合并掩码
双主线模型 uint32 紧凑位打包体积与 PCIe 5.0 带宽账本
Qwen3（V = 151,936）
4,748 个 uint32 = 18,992 B
B=64 仅 1.16 MiB (23.6 μs)
DeepSeek-V3（V = 129,280）
4,040 个 uint32 = 16,160 B
热表常驻 CPU L2/L3 缓存
将 15 万次在线下推栈模拟化简为 L2 查表与 <1% 边界按位或