1 小时音视频通话显存膨胀与分层声学/视觉词元修剪（算例 19-13）

1 小时（45,000 帧）全量保留
音文 76.5 万 + 视觉 92.16 万词元
共 168.66 万词元，耗尽显存算力

→

10 秒（125 帧）高保真滑窗
滑窗内保留完整 8 码本与近期视频
保障局部语调连贯与即时视觉指代

历史轮次“剥离声学残差 q_2..q_8、仅留语义锚点 q_1 + W_t”收益

历史帧每步从 17 词元压至 3 词元
保留用户/助手 q_1 与文本 W_t
纯音频 KV 显存节省 82.12%

→

音视频全模态 1 小时常驻词元：
从 1,686,600 压降至 139,310 词元
总 KV 显存节省达 91.74%（>85%）

远期对话靠语义码本与文本锚点维系记忆，近期滑窗维系声学自然度