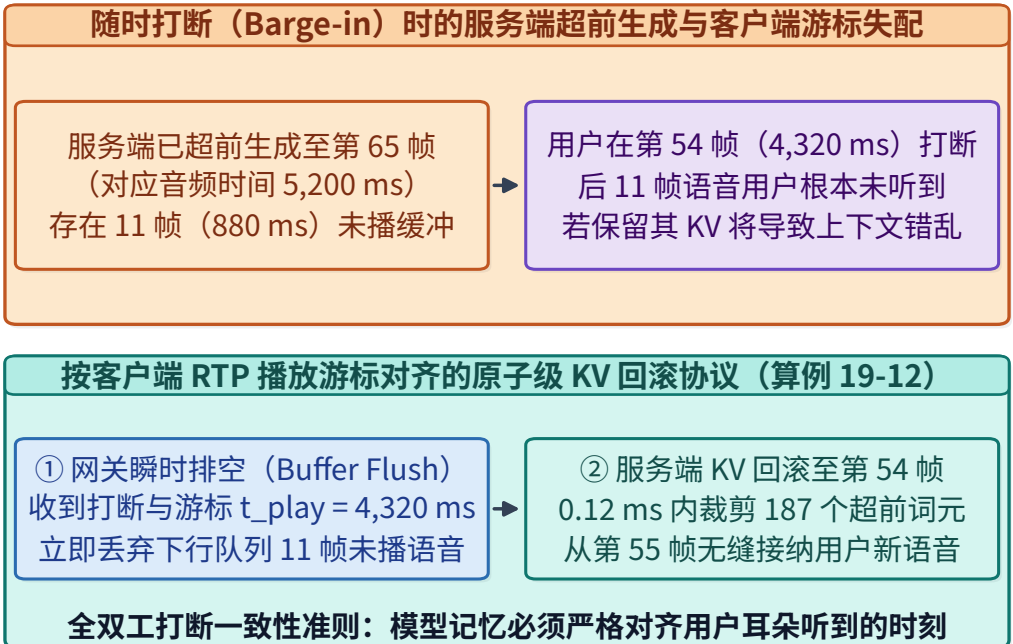
随时打断（Barge-in）时的服务端超前生成与客户端游标失配
服务端已超前生成至第 65 帧
（对应音频时间 5,200 ms）
存在 11 帧（880 ms）未播缓冲
用户在第 54 帧（4,320 ms）打断
后 11 帧语音用户根本未听到
若保留其 KV 将导致上下文错乱
按客户端 RTP 播放游标对齐的原子级 KV 回滚协议（算例 19-12）
① 网关瞬时排空（Buffer Flush）
收到打断与游标 t_play = 4,320 ms
立即丢弃下行队列 11 帧未播语音
② 服务端 KV 回滚至第 54 帧
0.12 ms 内裁剪 187 个超前词元
从第 55 帧无缝接纳用户新语音
全双工打断一致性准则：模型记忆必须严格对齐用户耳朵听到的时刻