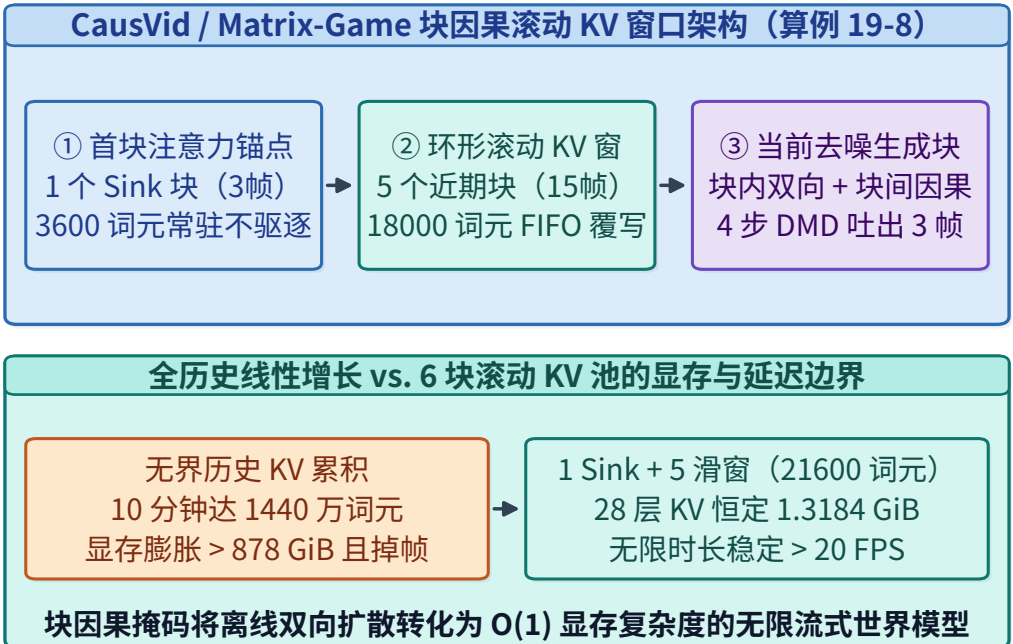
CausVid / Matrix-Game 块因果滚动 KV 窗口架构（算例 19-8）
① 首块注意力锚点
1 个 Sink 块（3帧）
3600 词元常驻不驱逐
② 环形滚动 KV 窗
5 个近期块（15帧）
18000 词元 FIFO 覆写
③ 当前去噪生成块
块内双向 + 块间因果
4 步 DMD 吐出 3 帧
全历史线性增长 vs. 6 块滚动 KV 池的显存与延迟边界
无界历史 KV 累积
10 分钟达 1440 万词元
显存膨胀 > 878 GiB 且掉帧
1 Sink + 5 滑窗（21600 词元）
28 层 KV 恒定 1.3184 GiB
无限时长稳定 > 20 FPS
块因果掩码将离线双向扩散转化为 O(1) 显存复杂度的无限流式世界模型